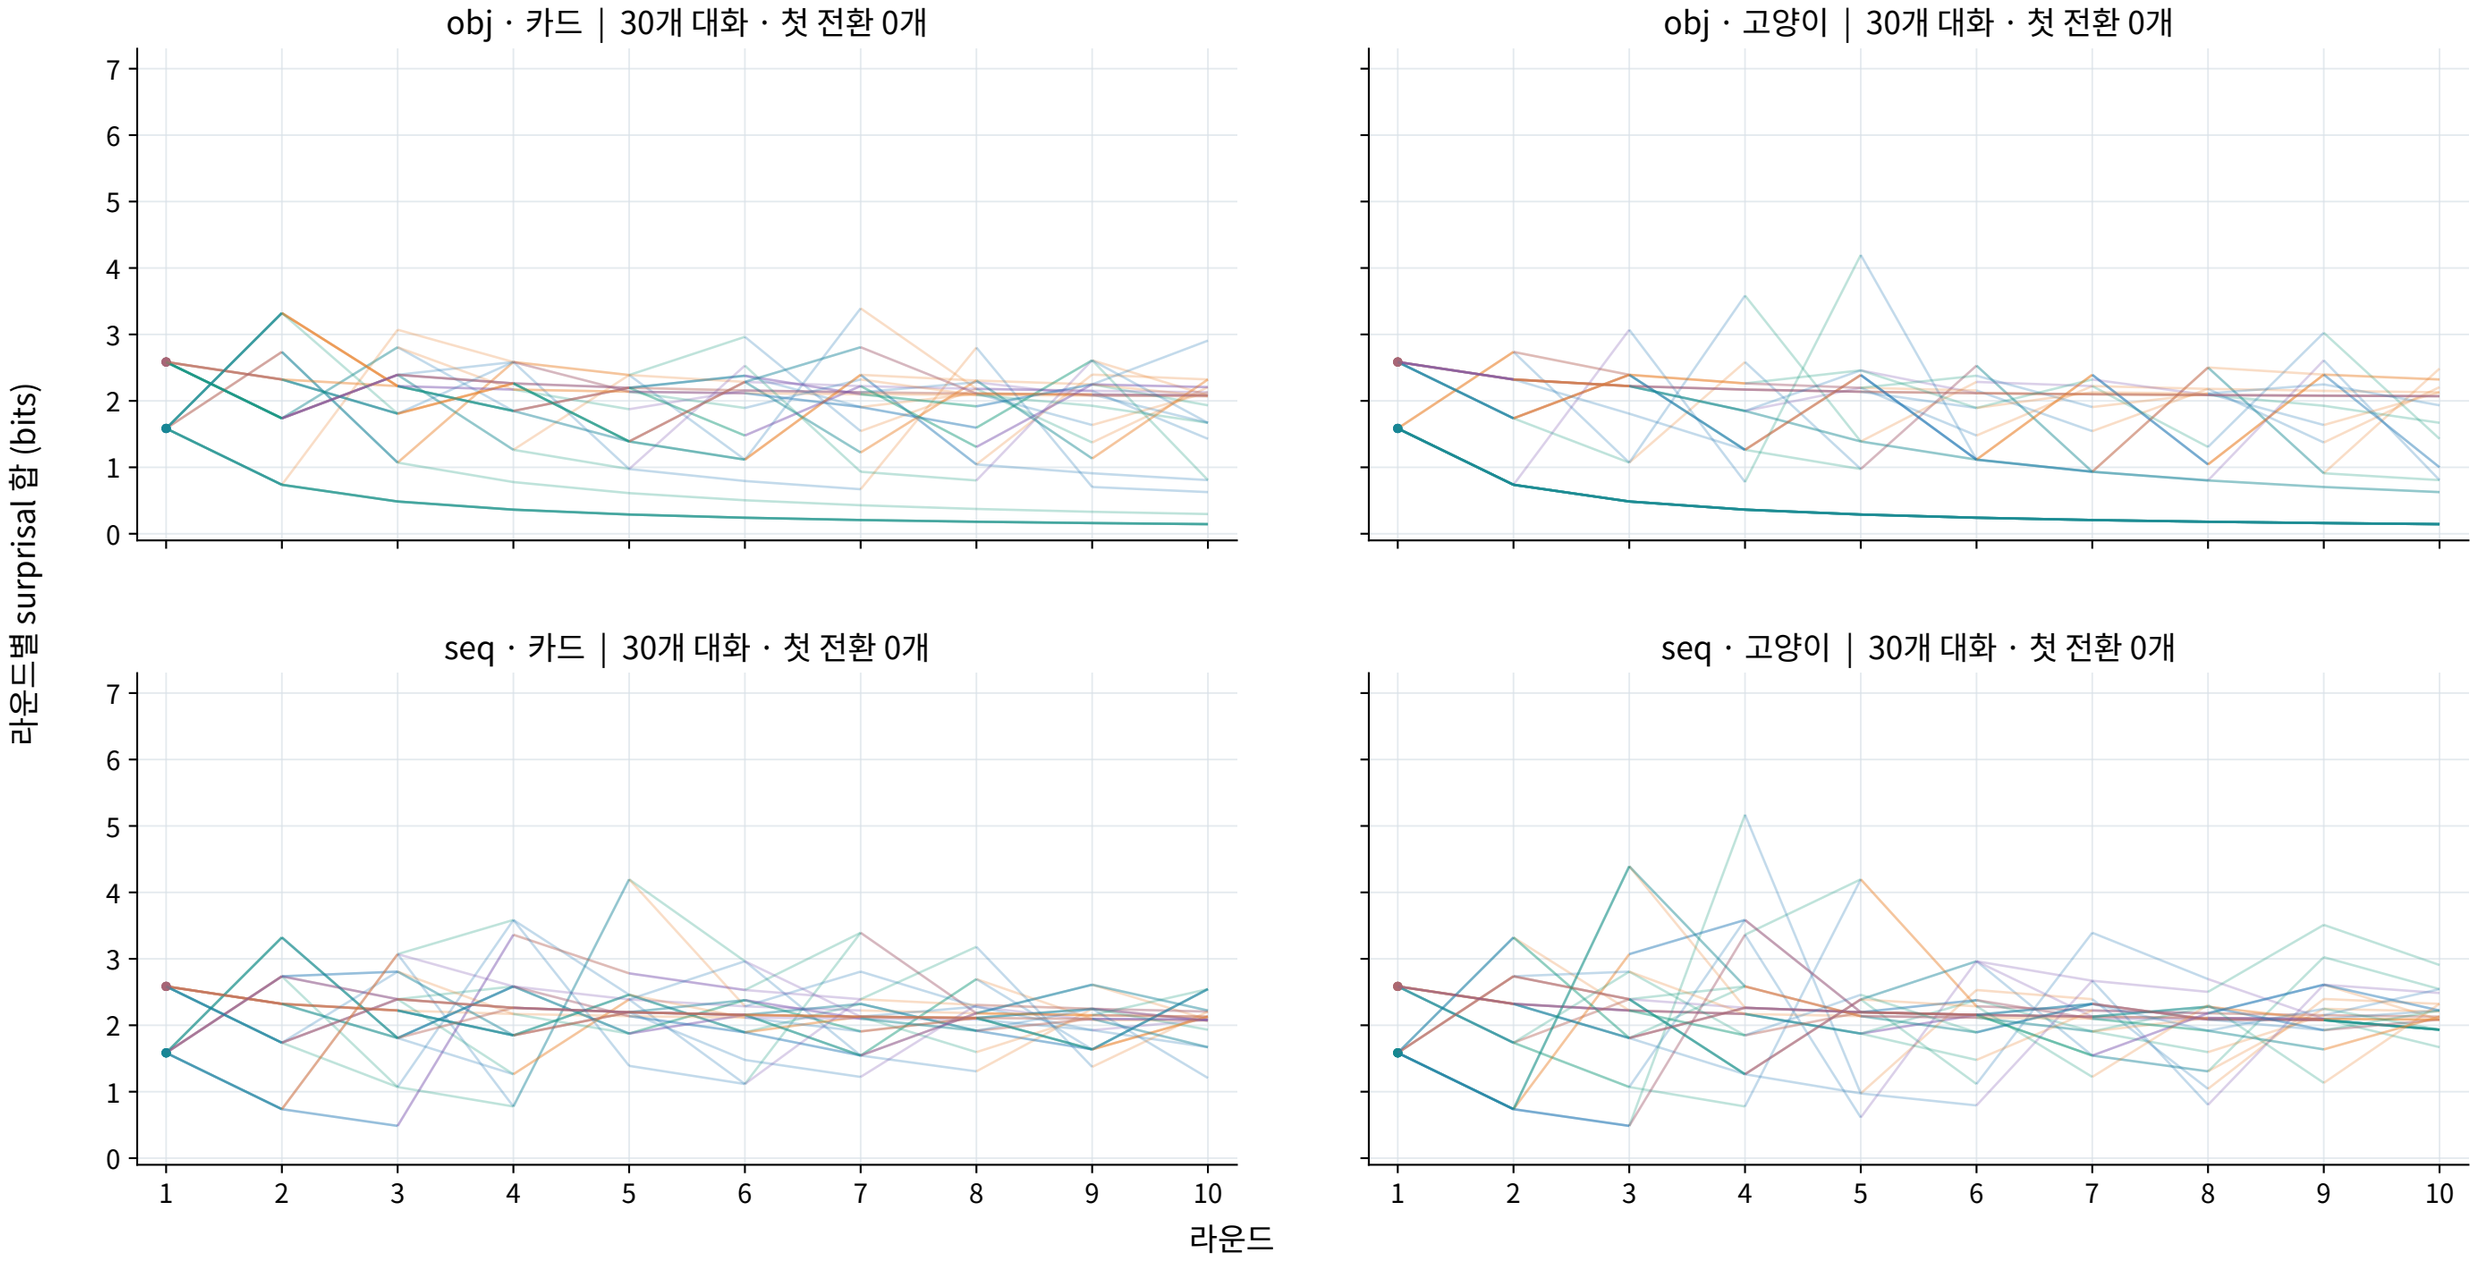
gpt-5.6-luna-low | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.

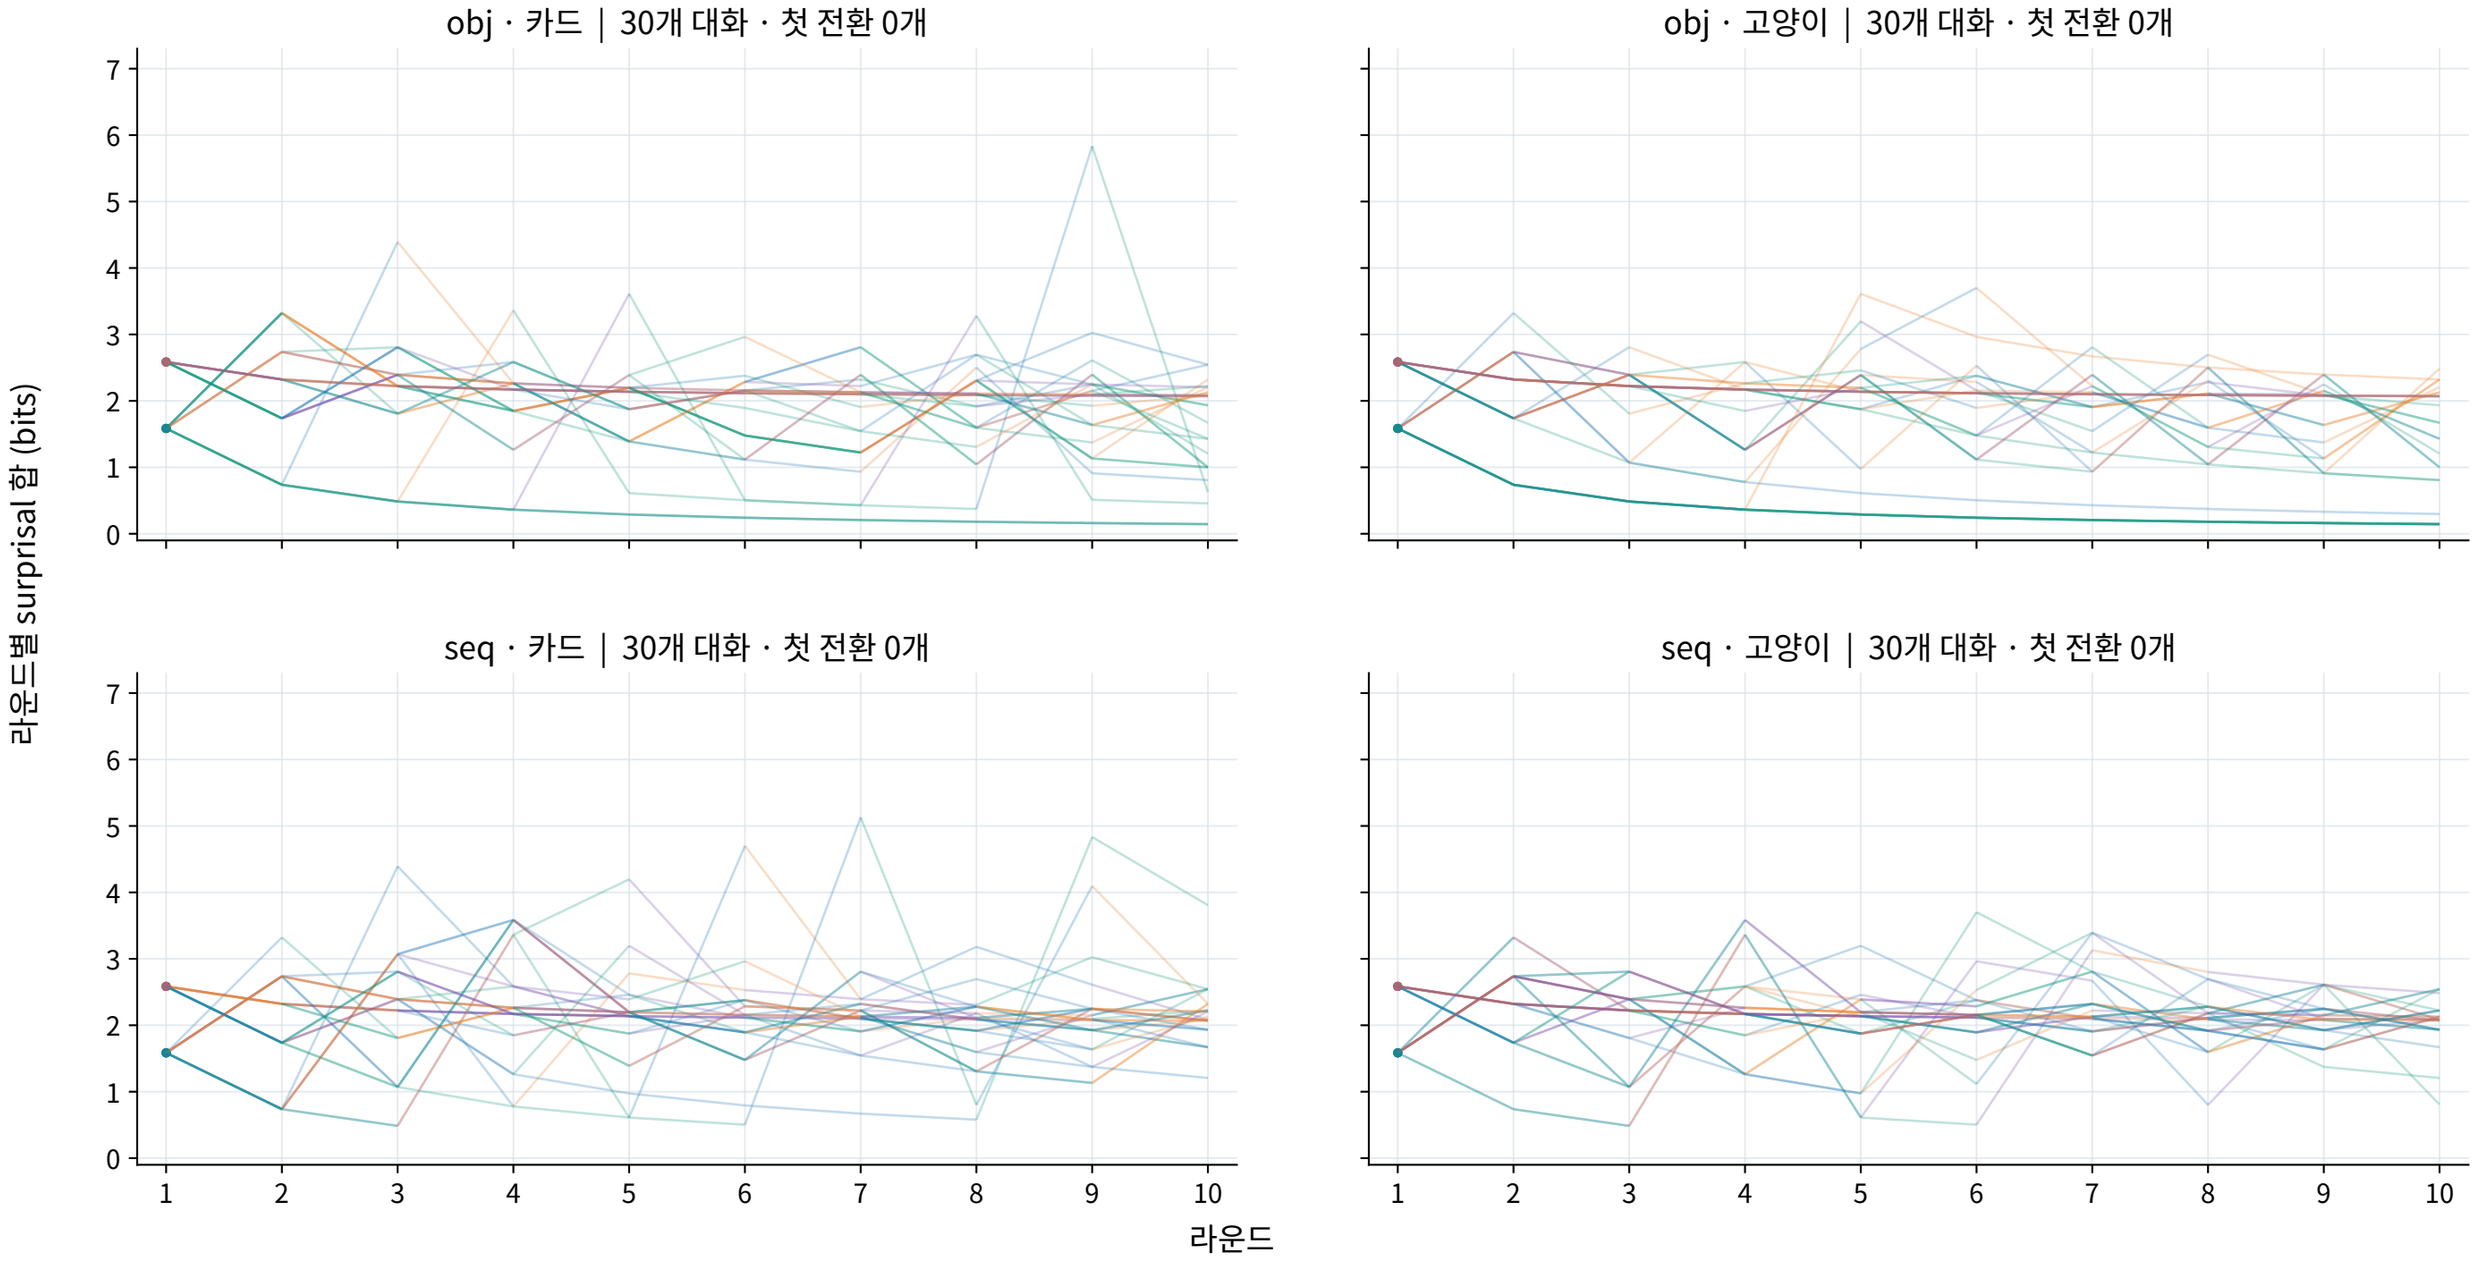


gpt-5.6-luna-medium | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.

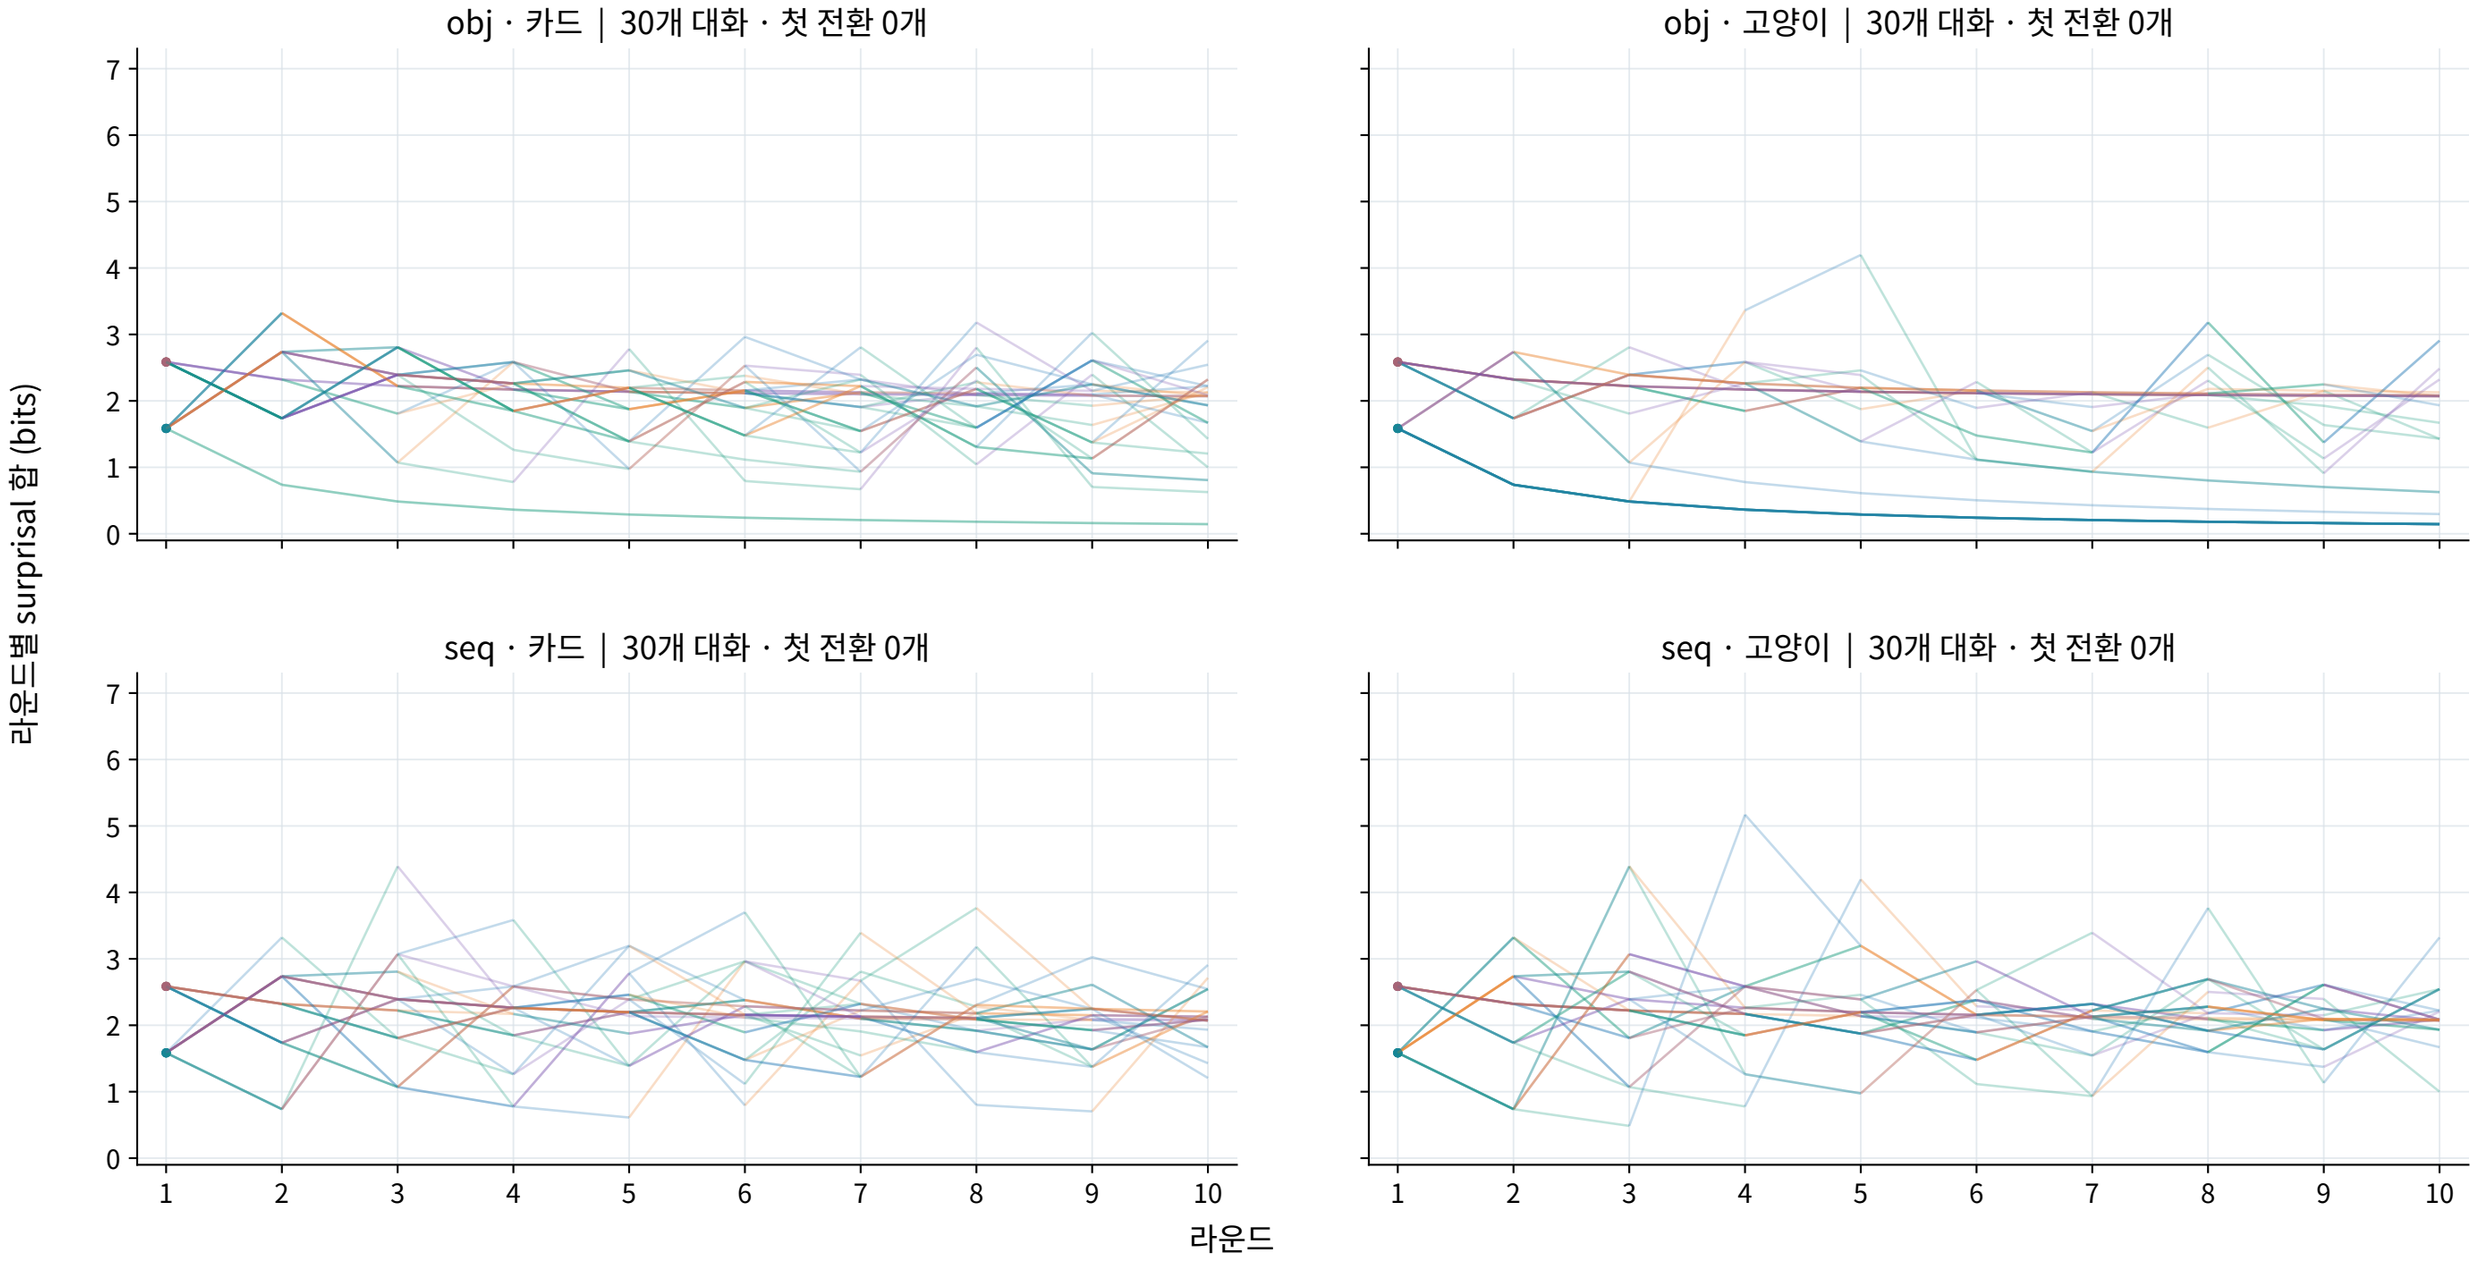


gpt-5.6-luna-high | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.



gpt-5.6-terra-low | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.

obj · 카드 | 30개 대화 · 첫 전환 2개

obj · 고양이 | 30개 대화 · 첫 전환 1개

seq · 카드 | 30개 대화 · 첫 전환 0개

seq · 고양이 | 30개 대화 · 첫 전환 0개

라운드별 surprisal 합 (bits)

라운드

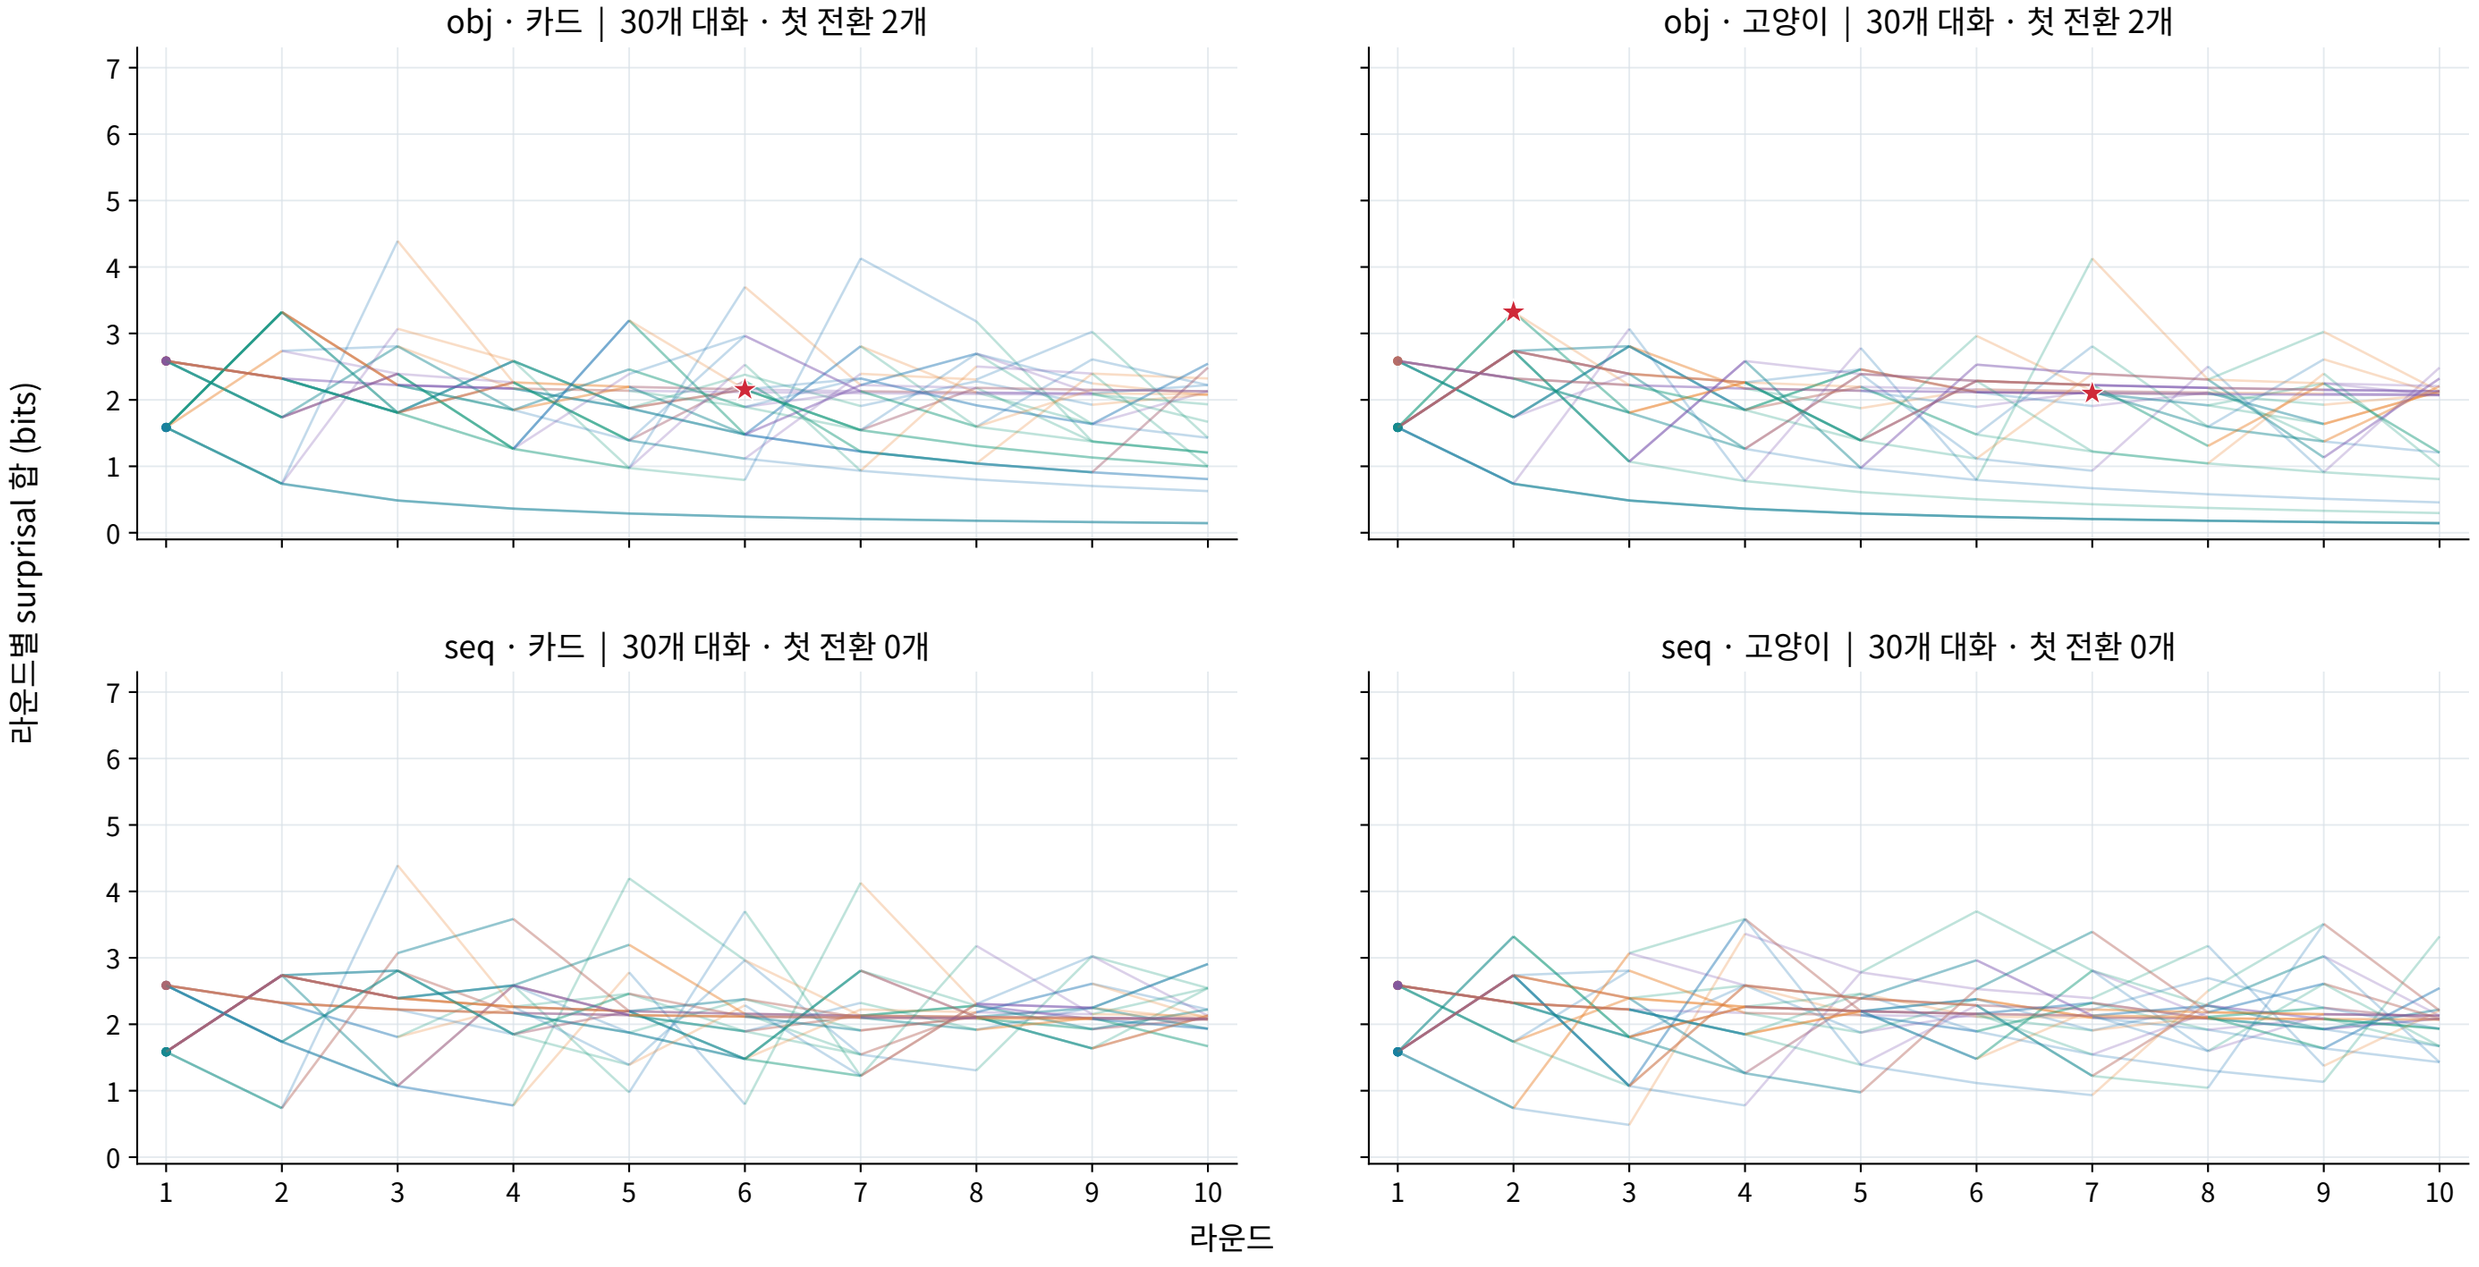
KK KD DK DD ★ 최초 공동 보고

gpt-5.6-terra-medium | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.

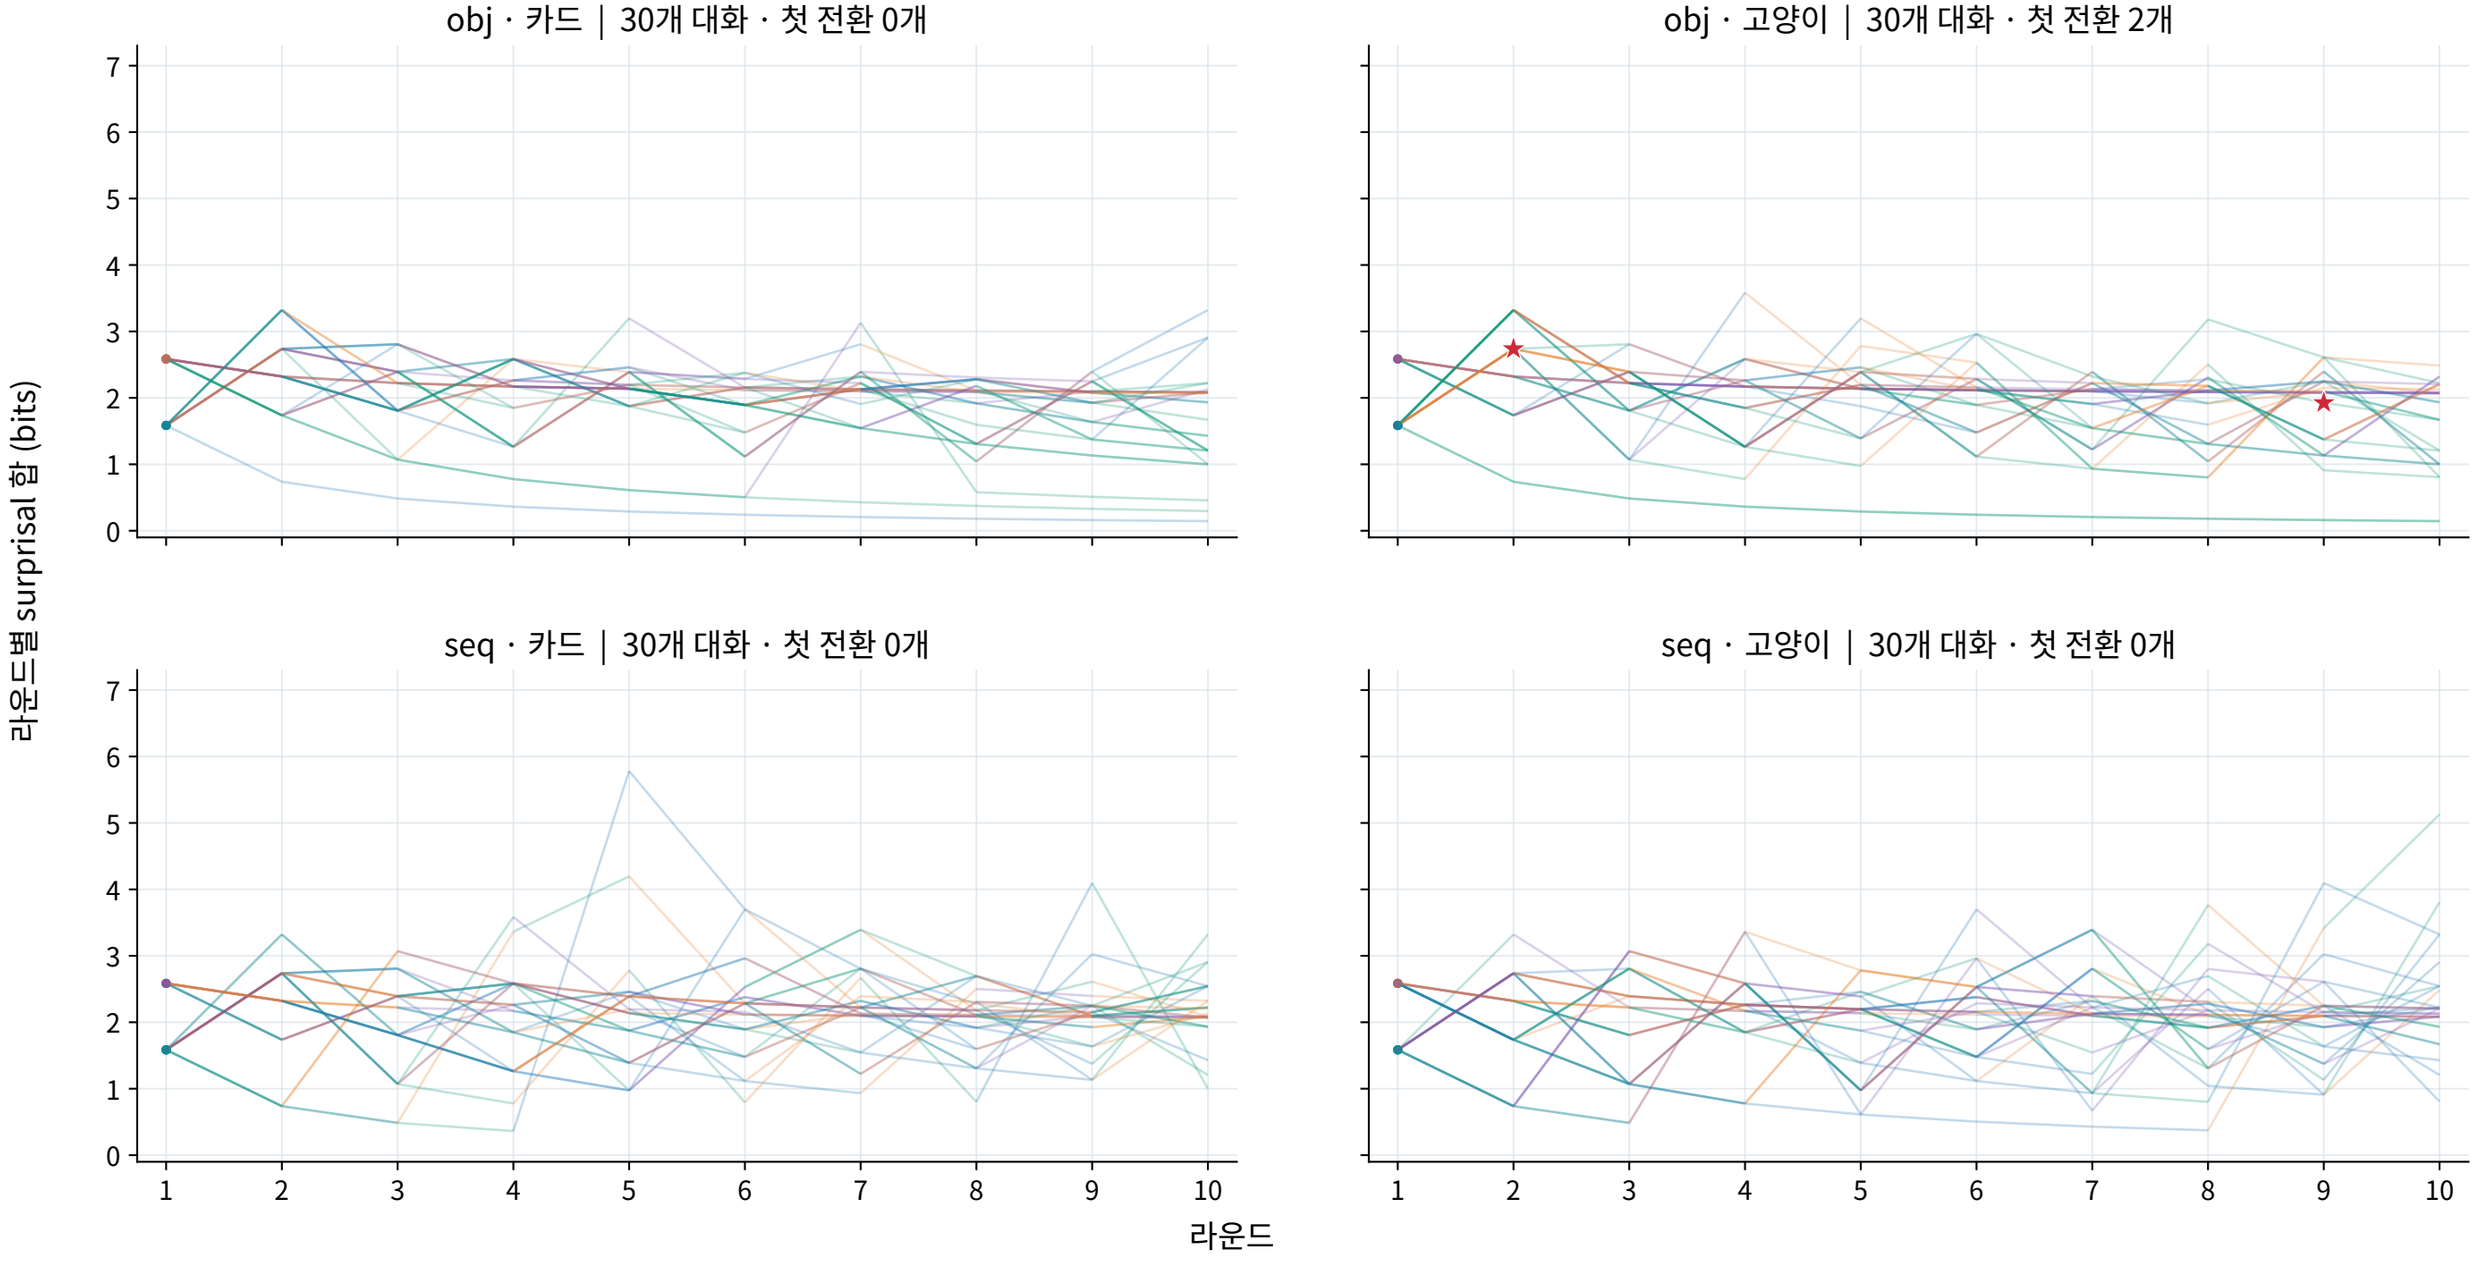


gpt-5.6-terra-high | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.

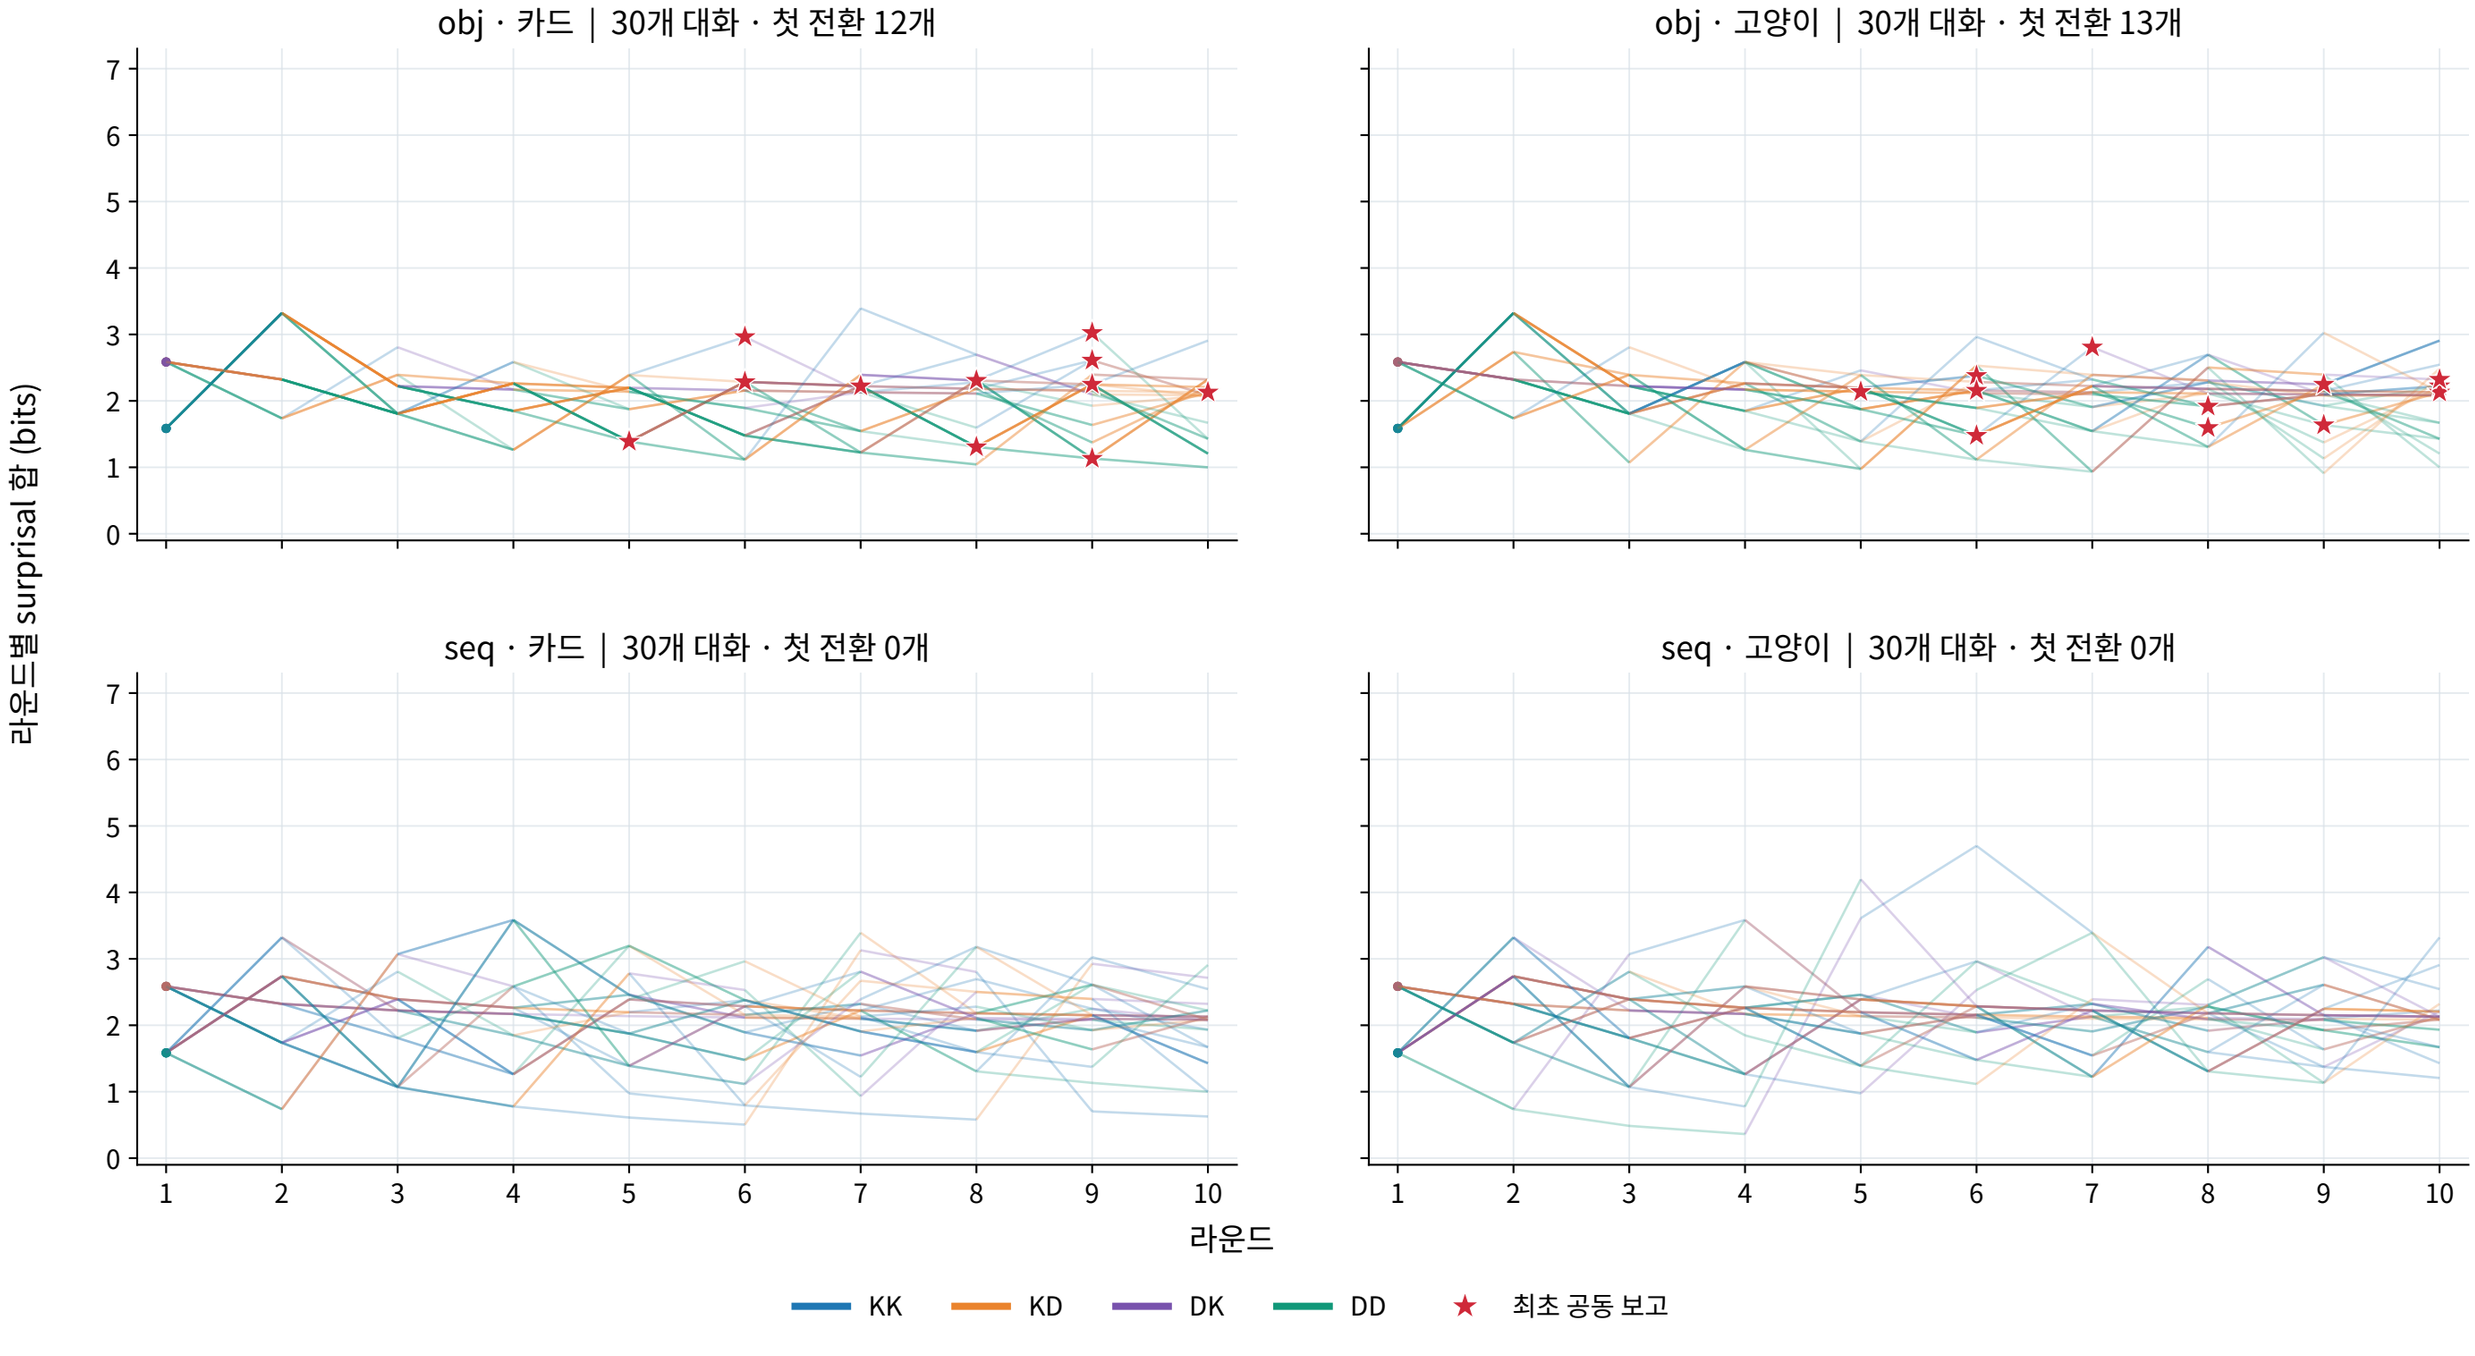


gpt-5.6-sol-low | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.

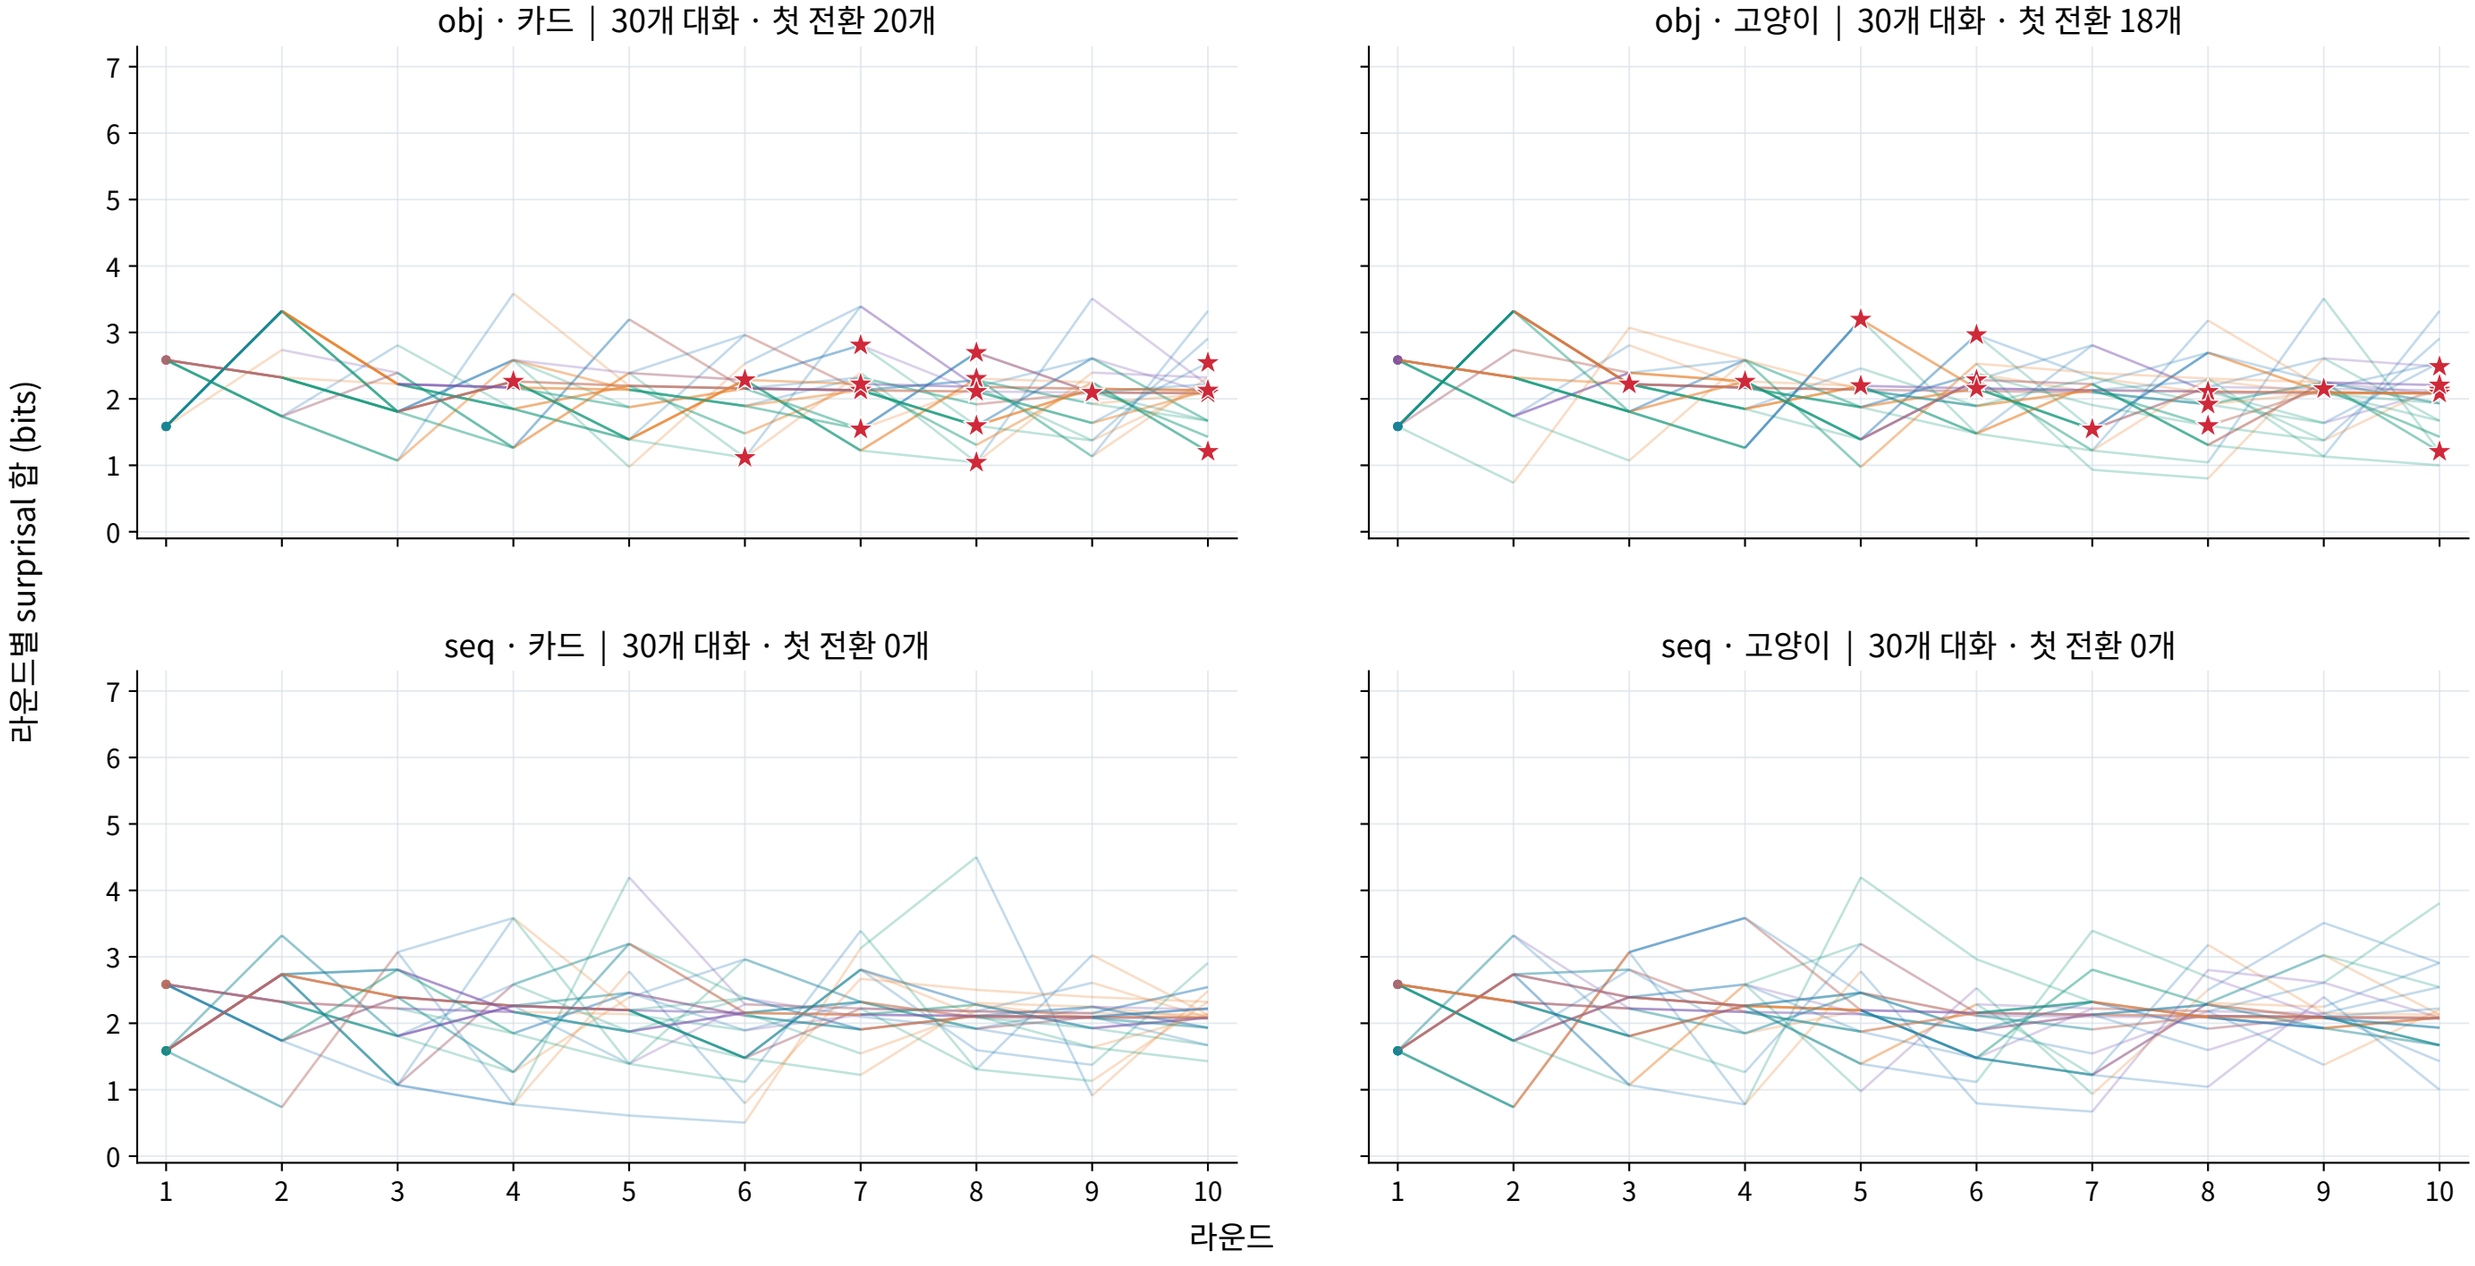


gpt-5.6-sol-medium | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.

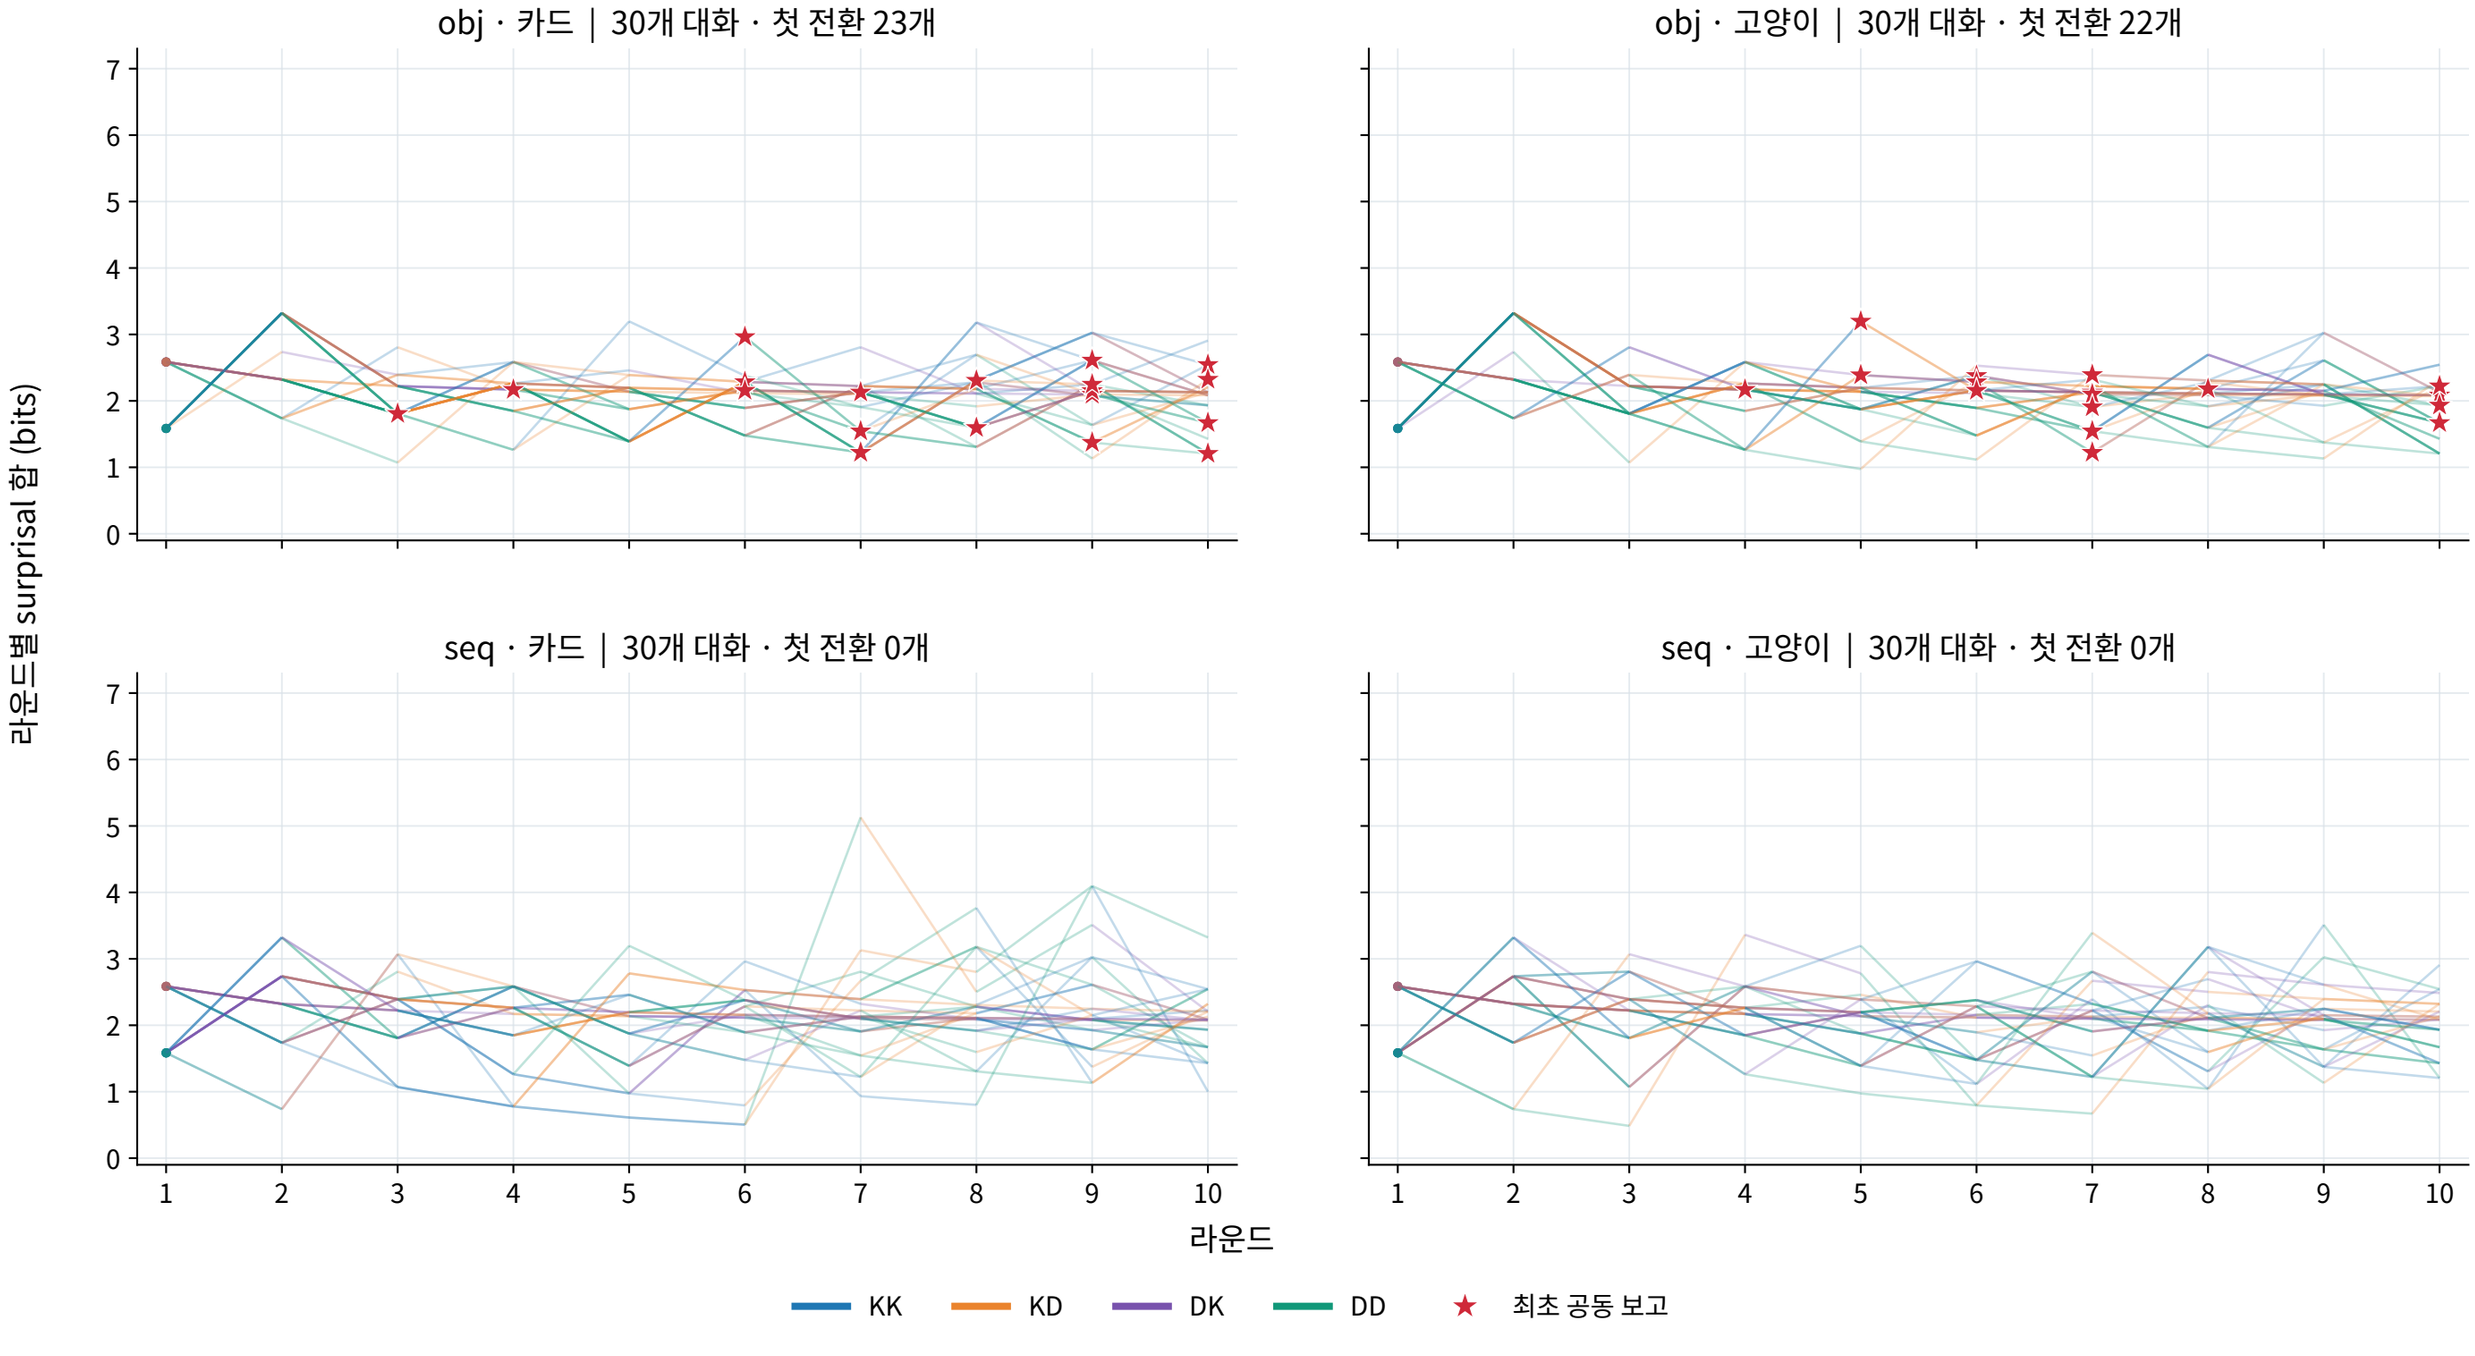


gpt-5.6-sol-high | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.

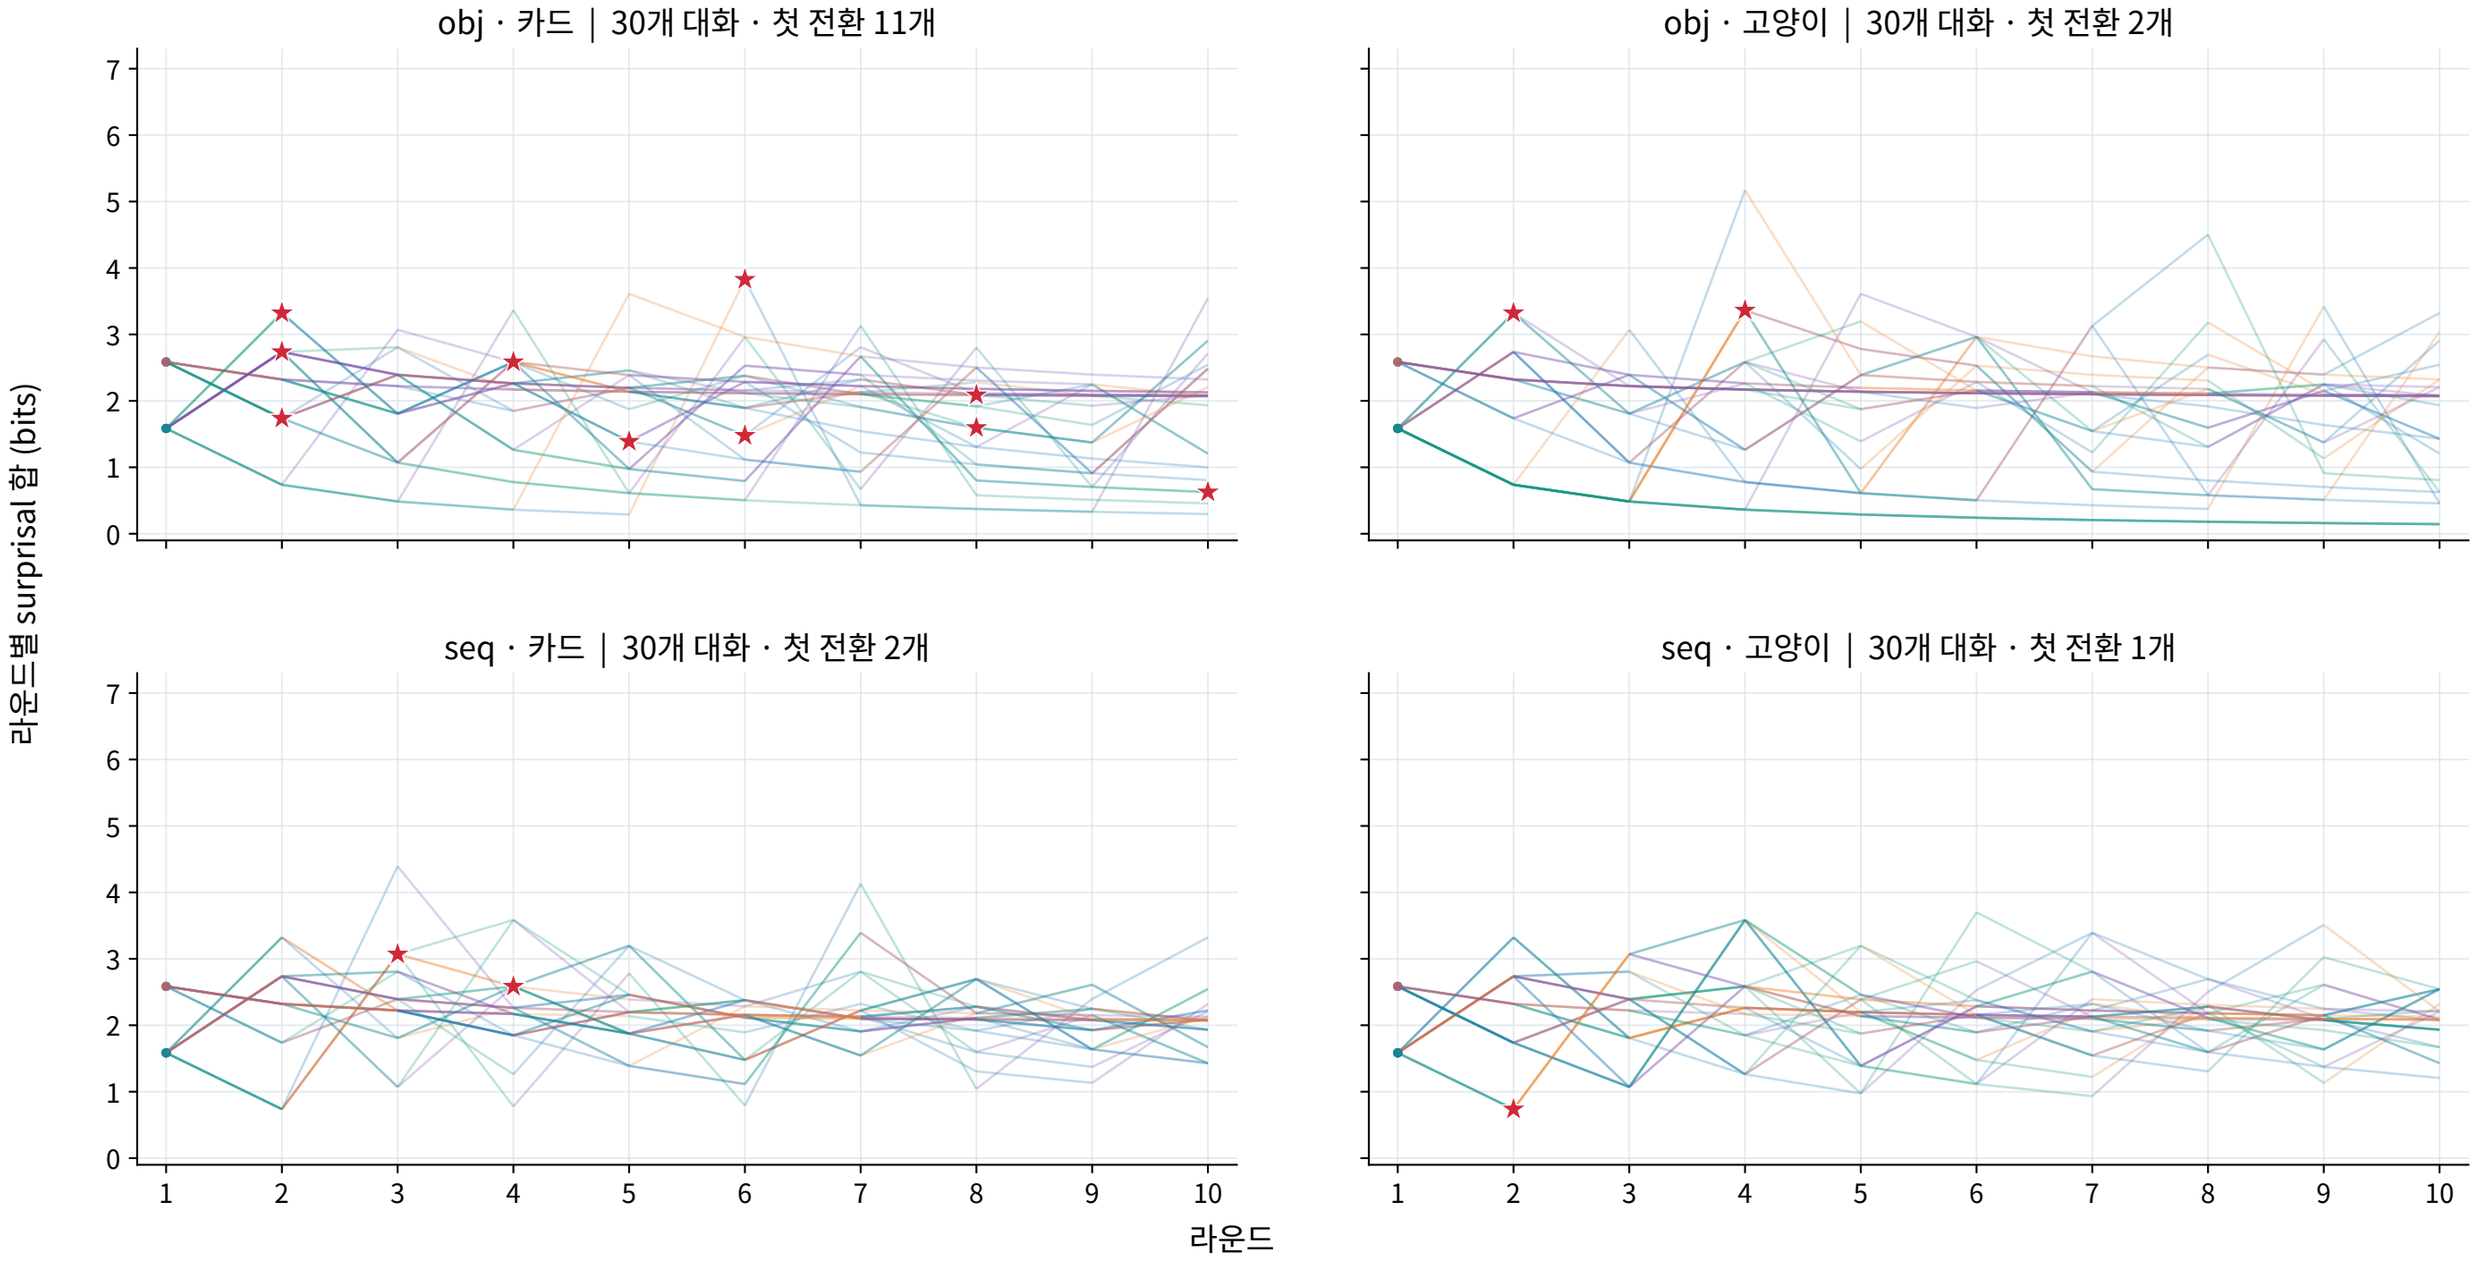


gpt-6-luna-low | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.

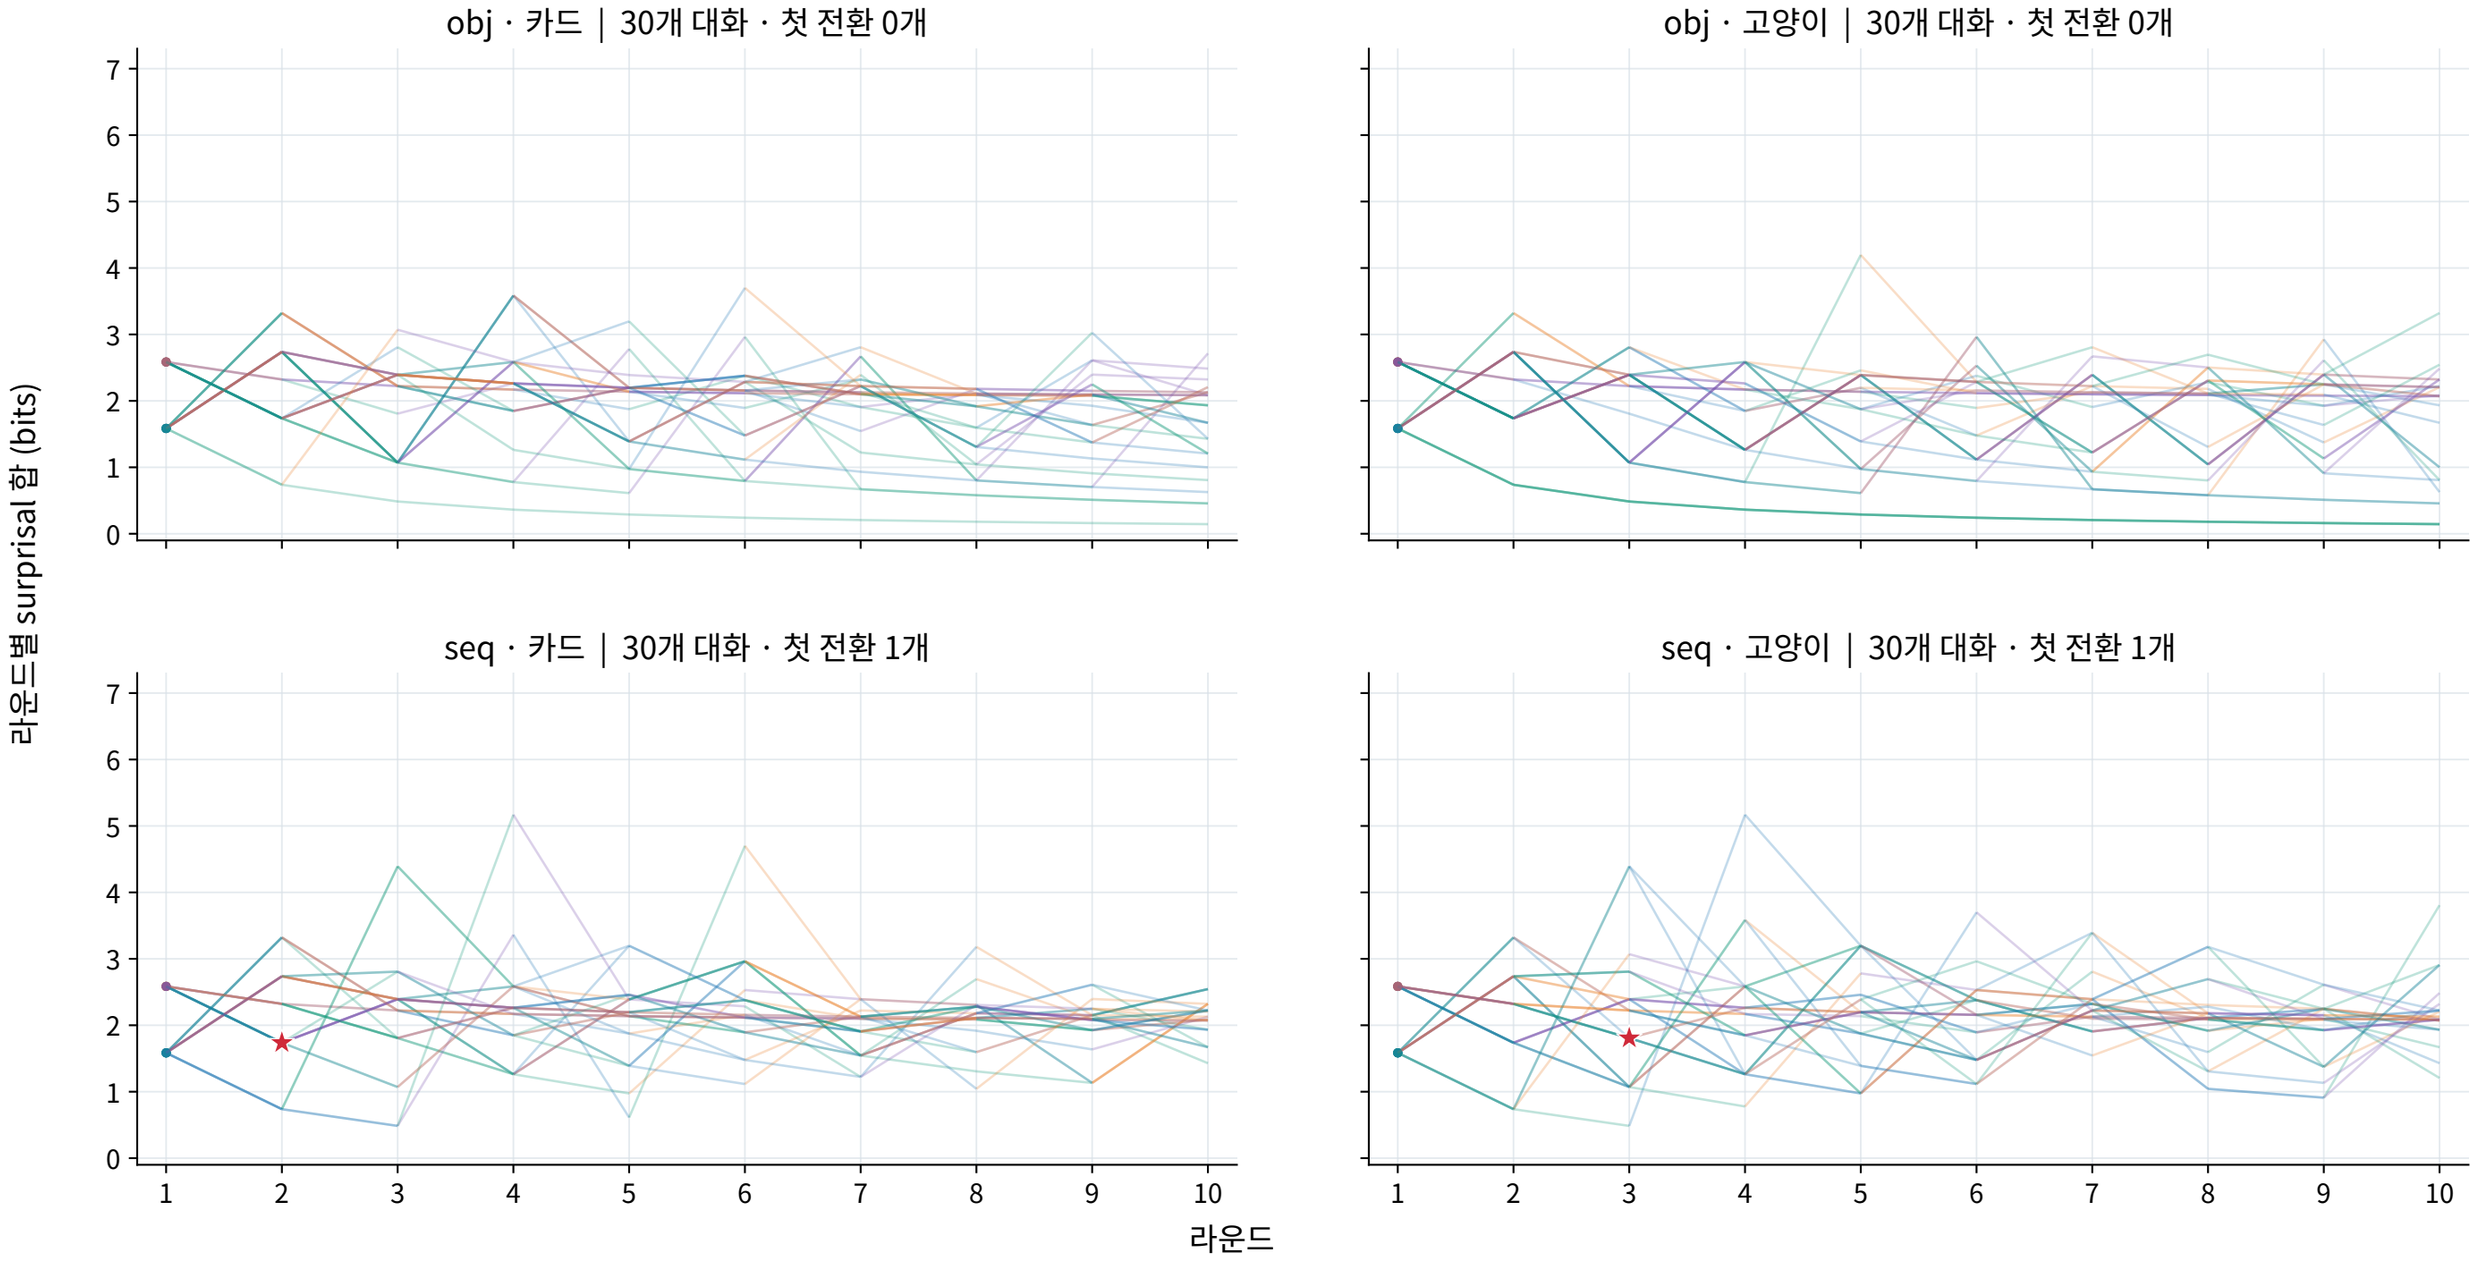


gpt-6-luna-medium | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.

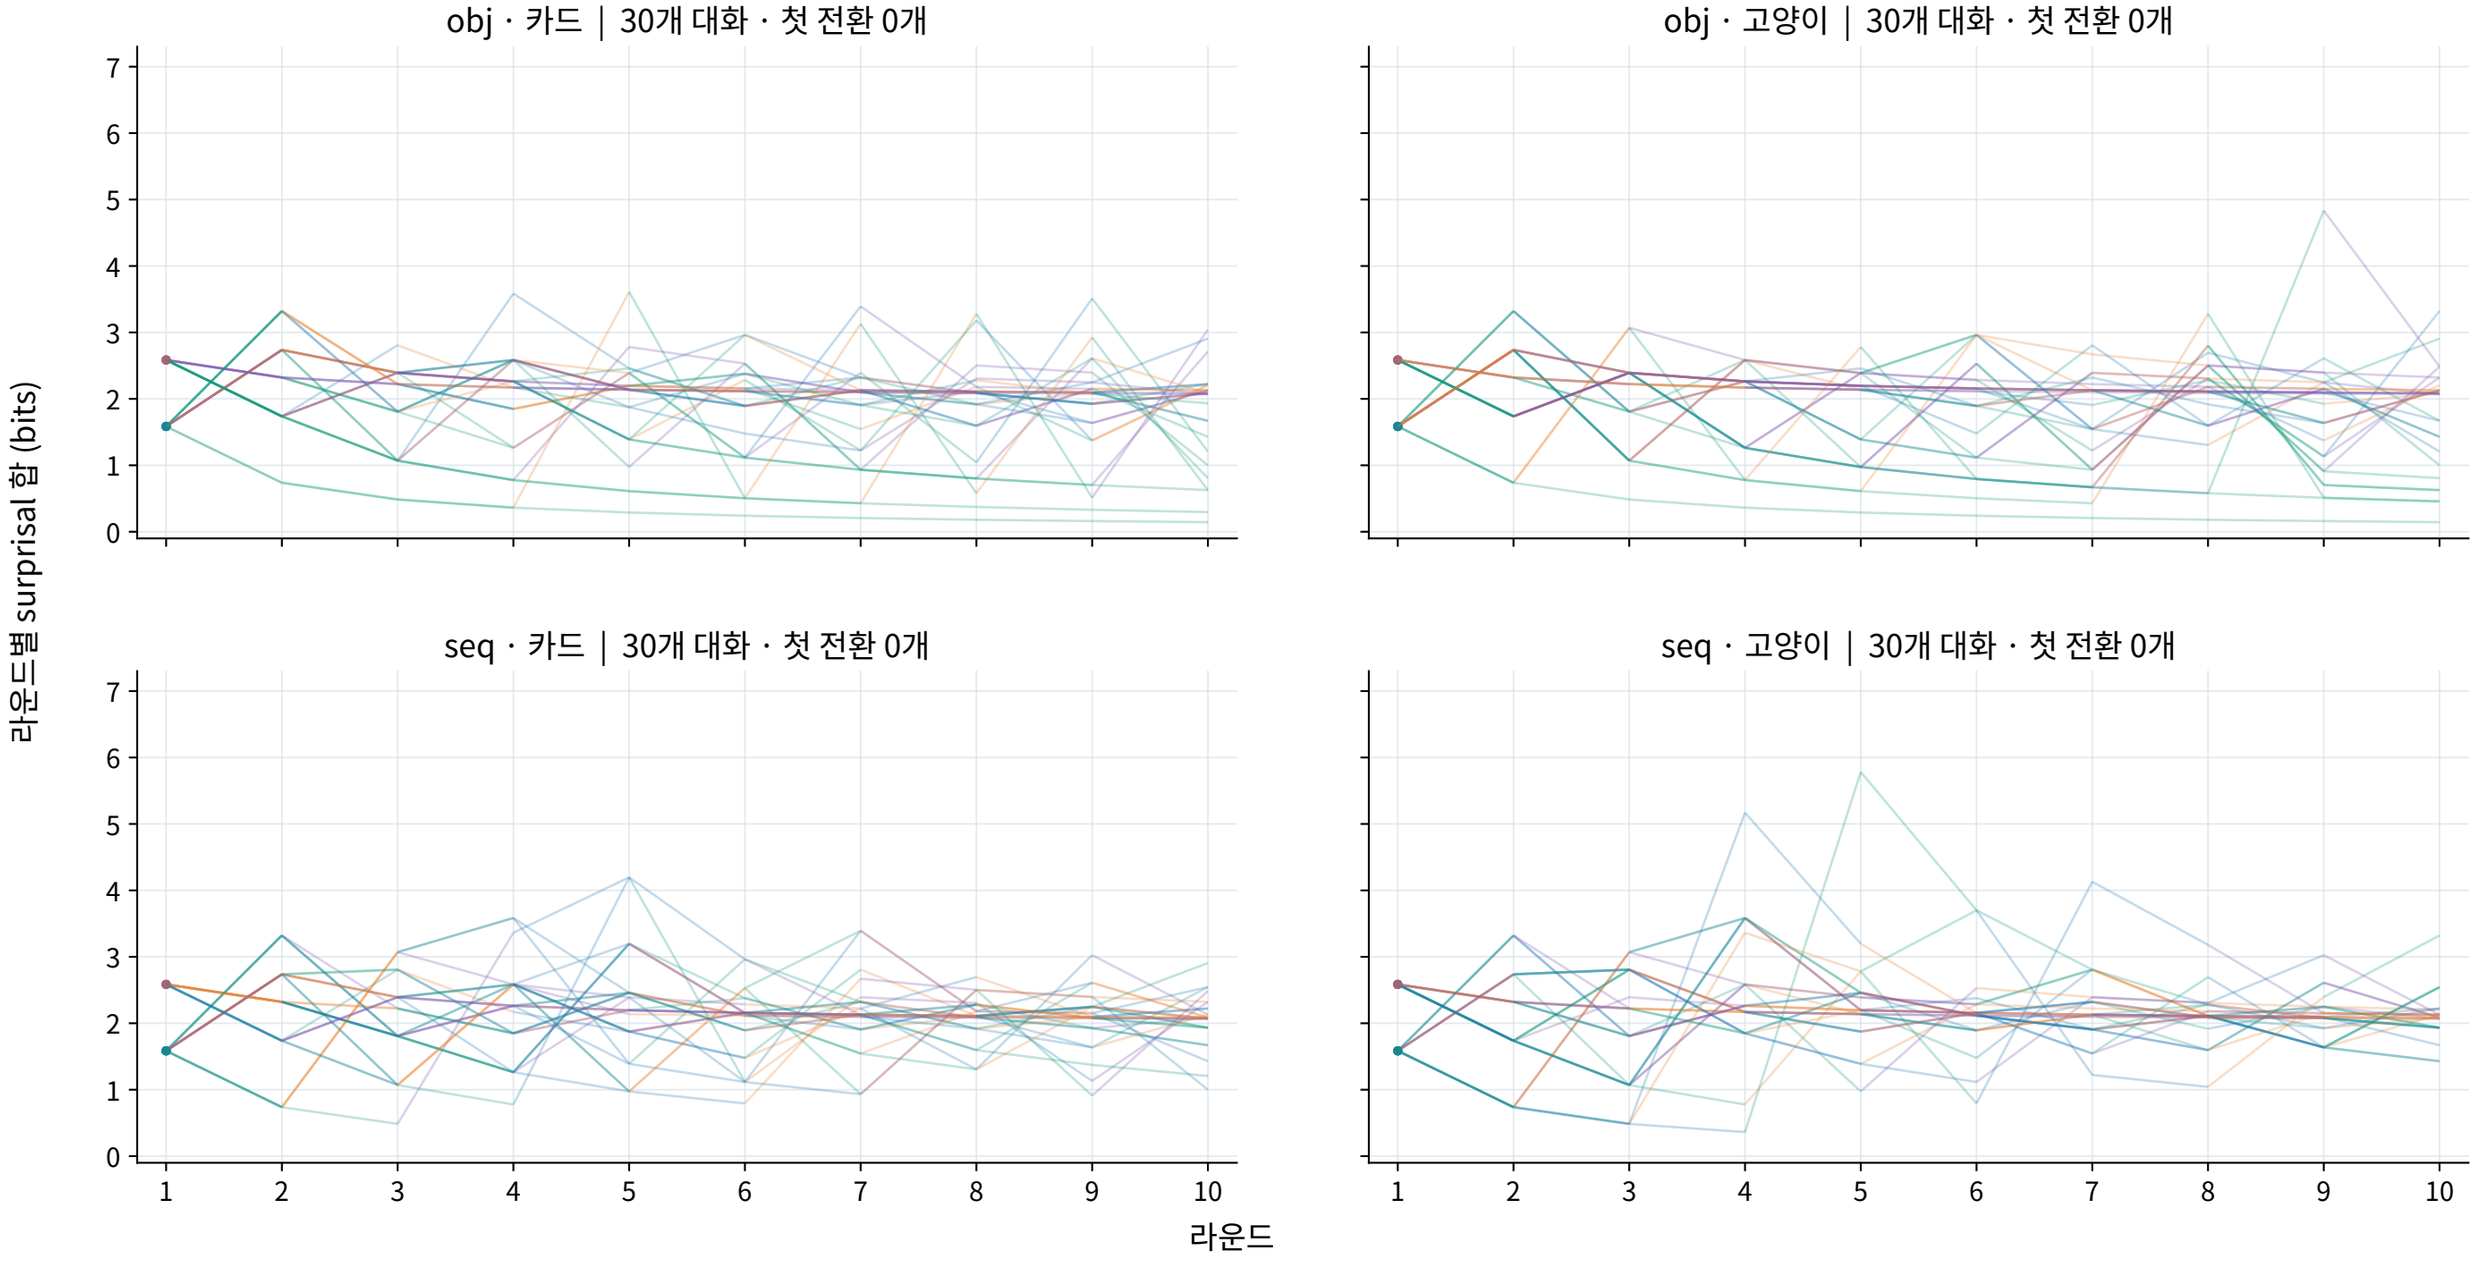


gpt-6-luna-high | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.

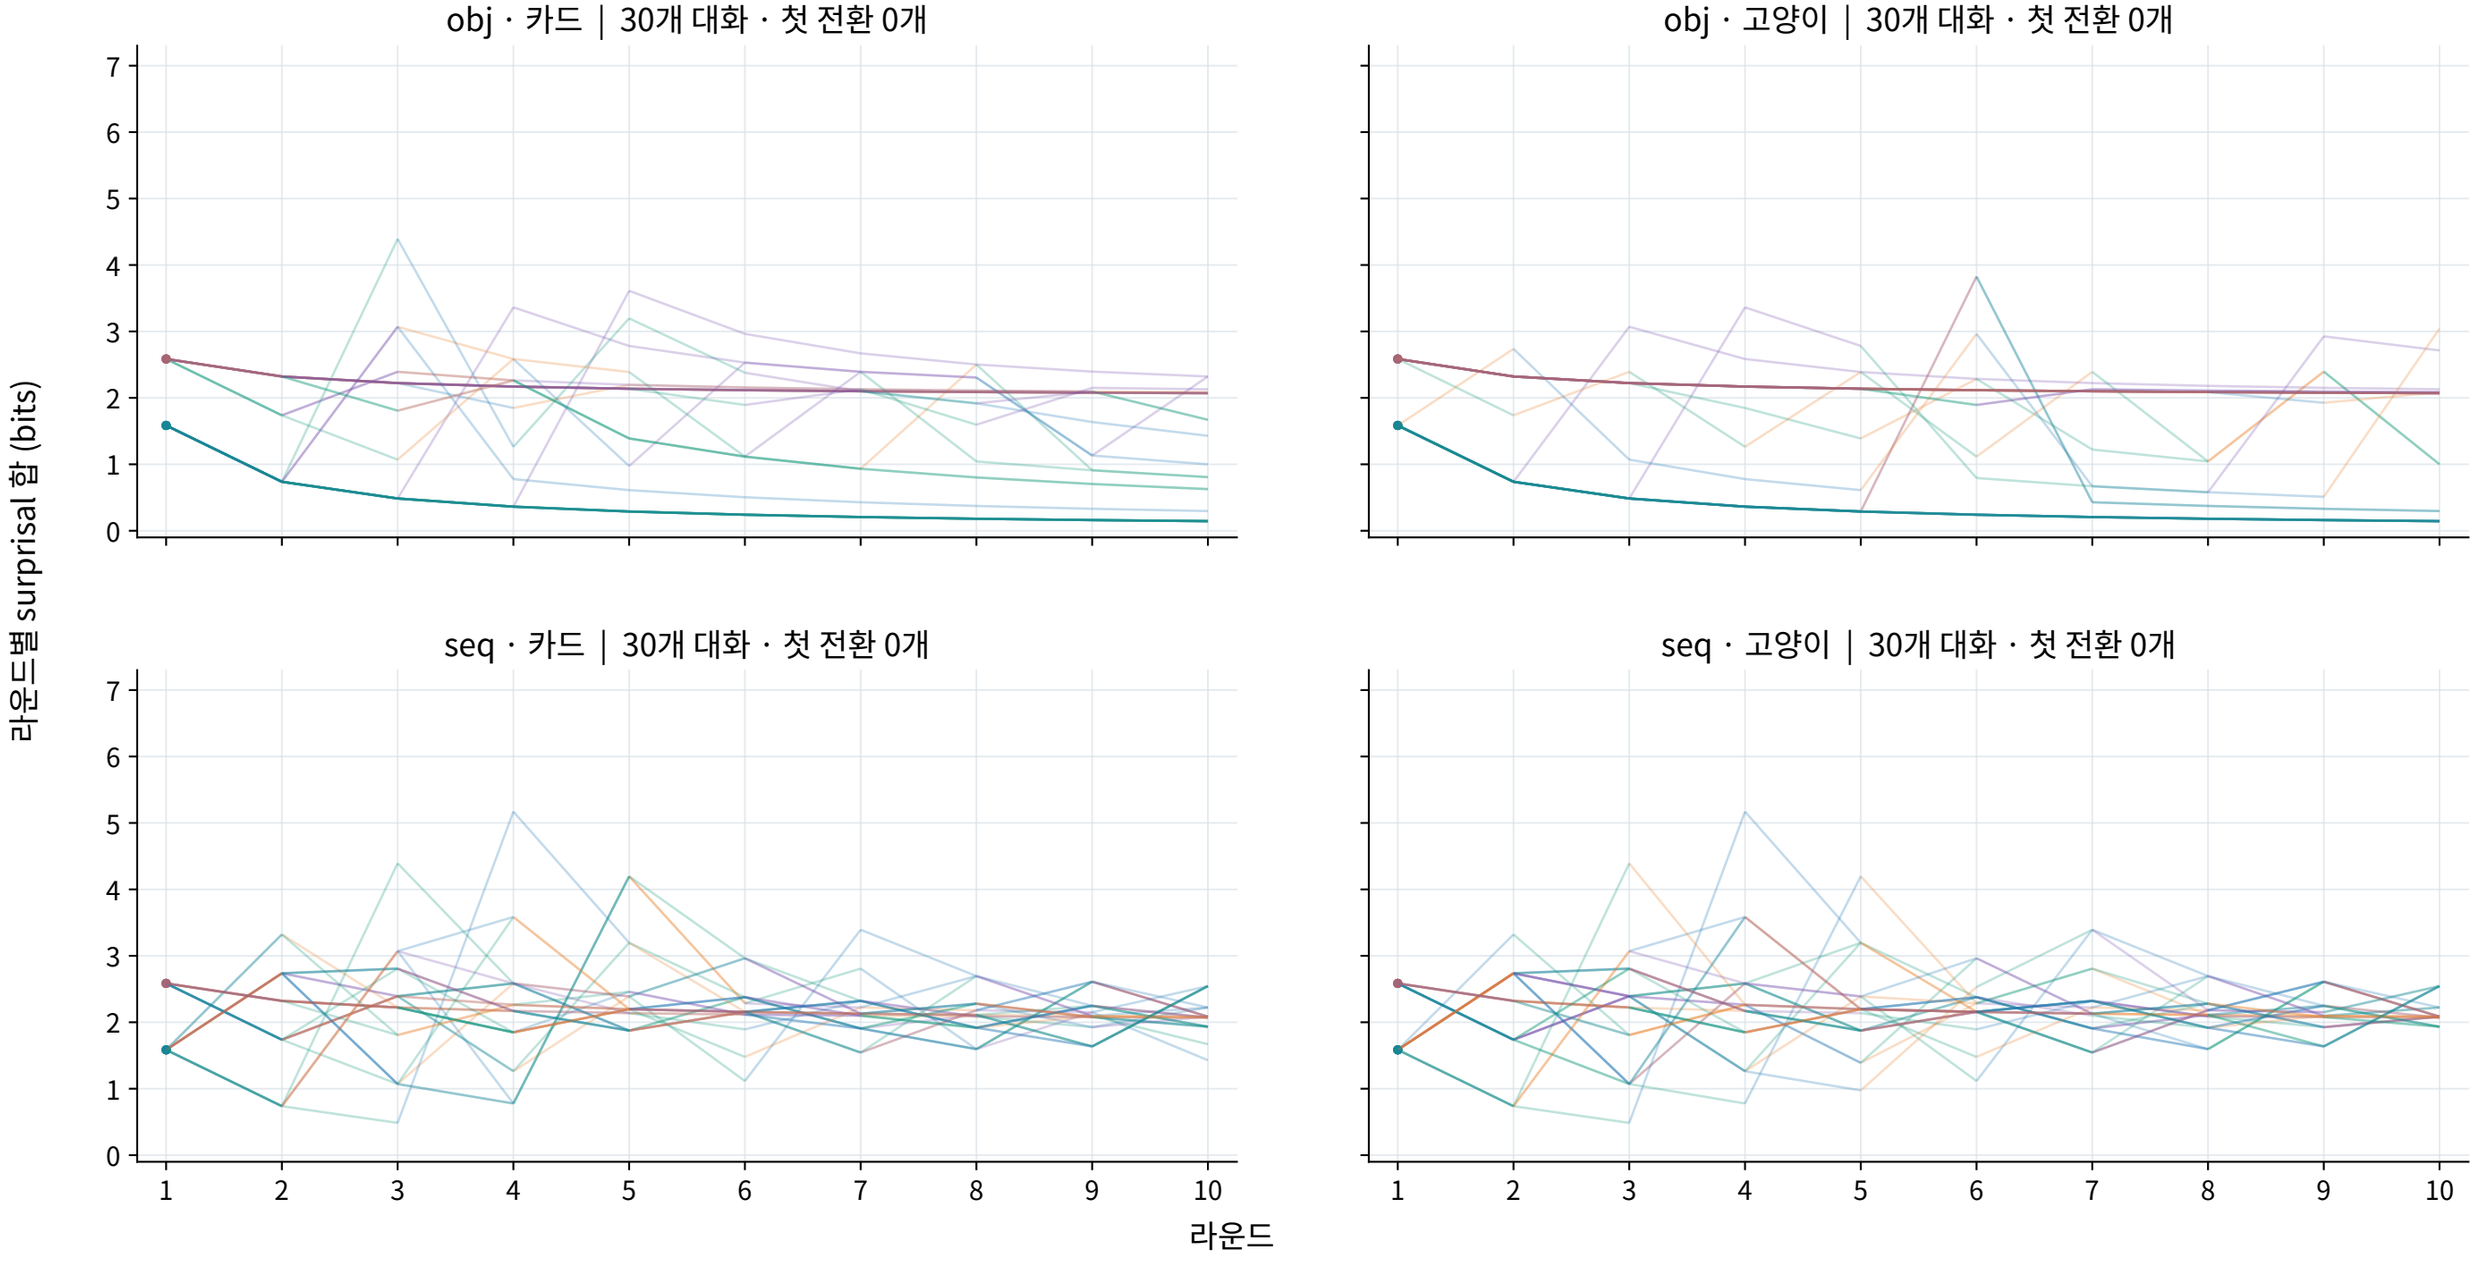


gpt-6-sol-low | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.

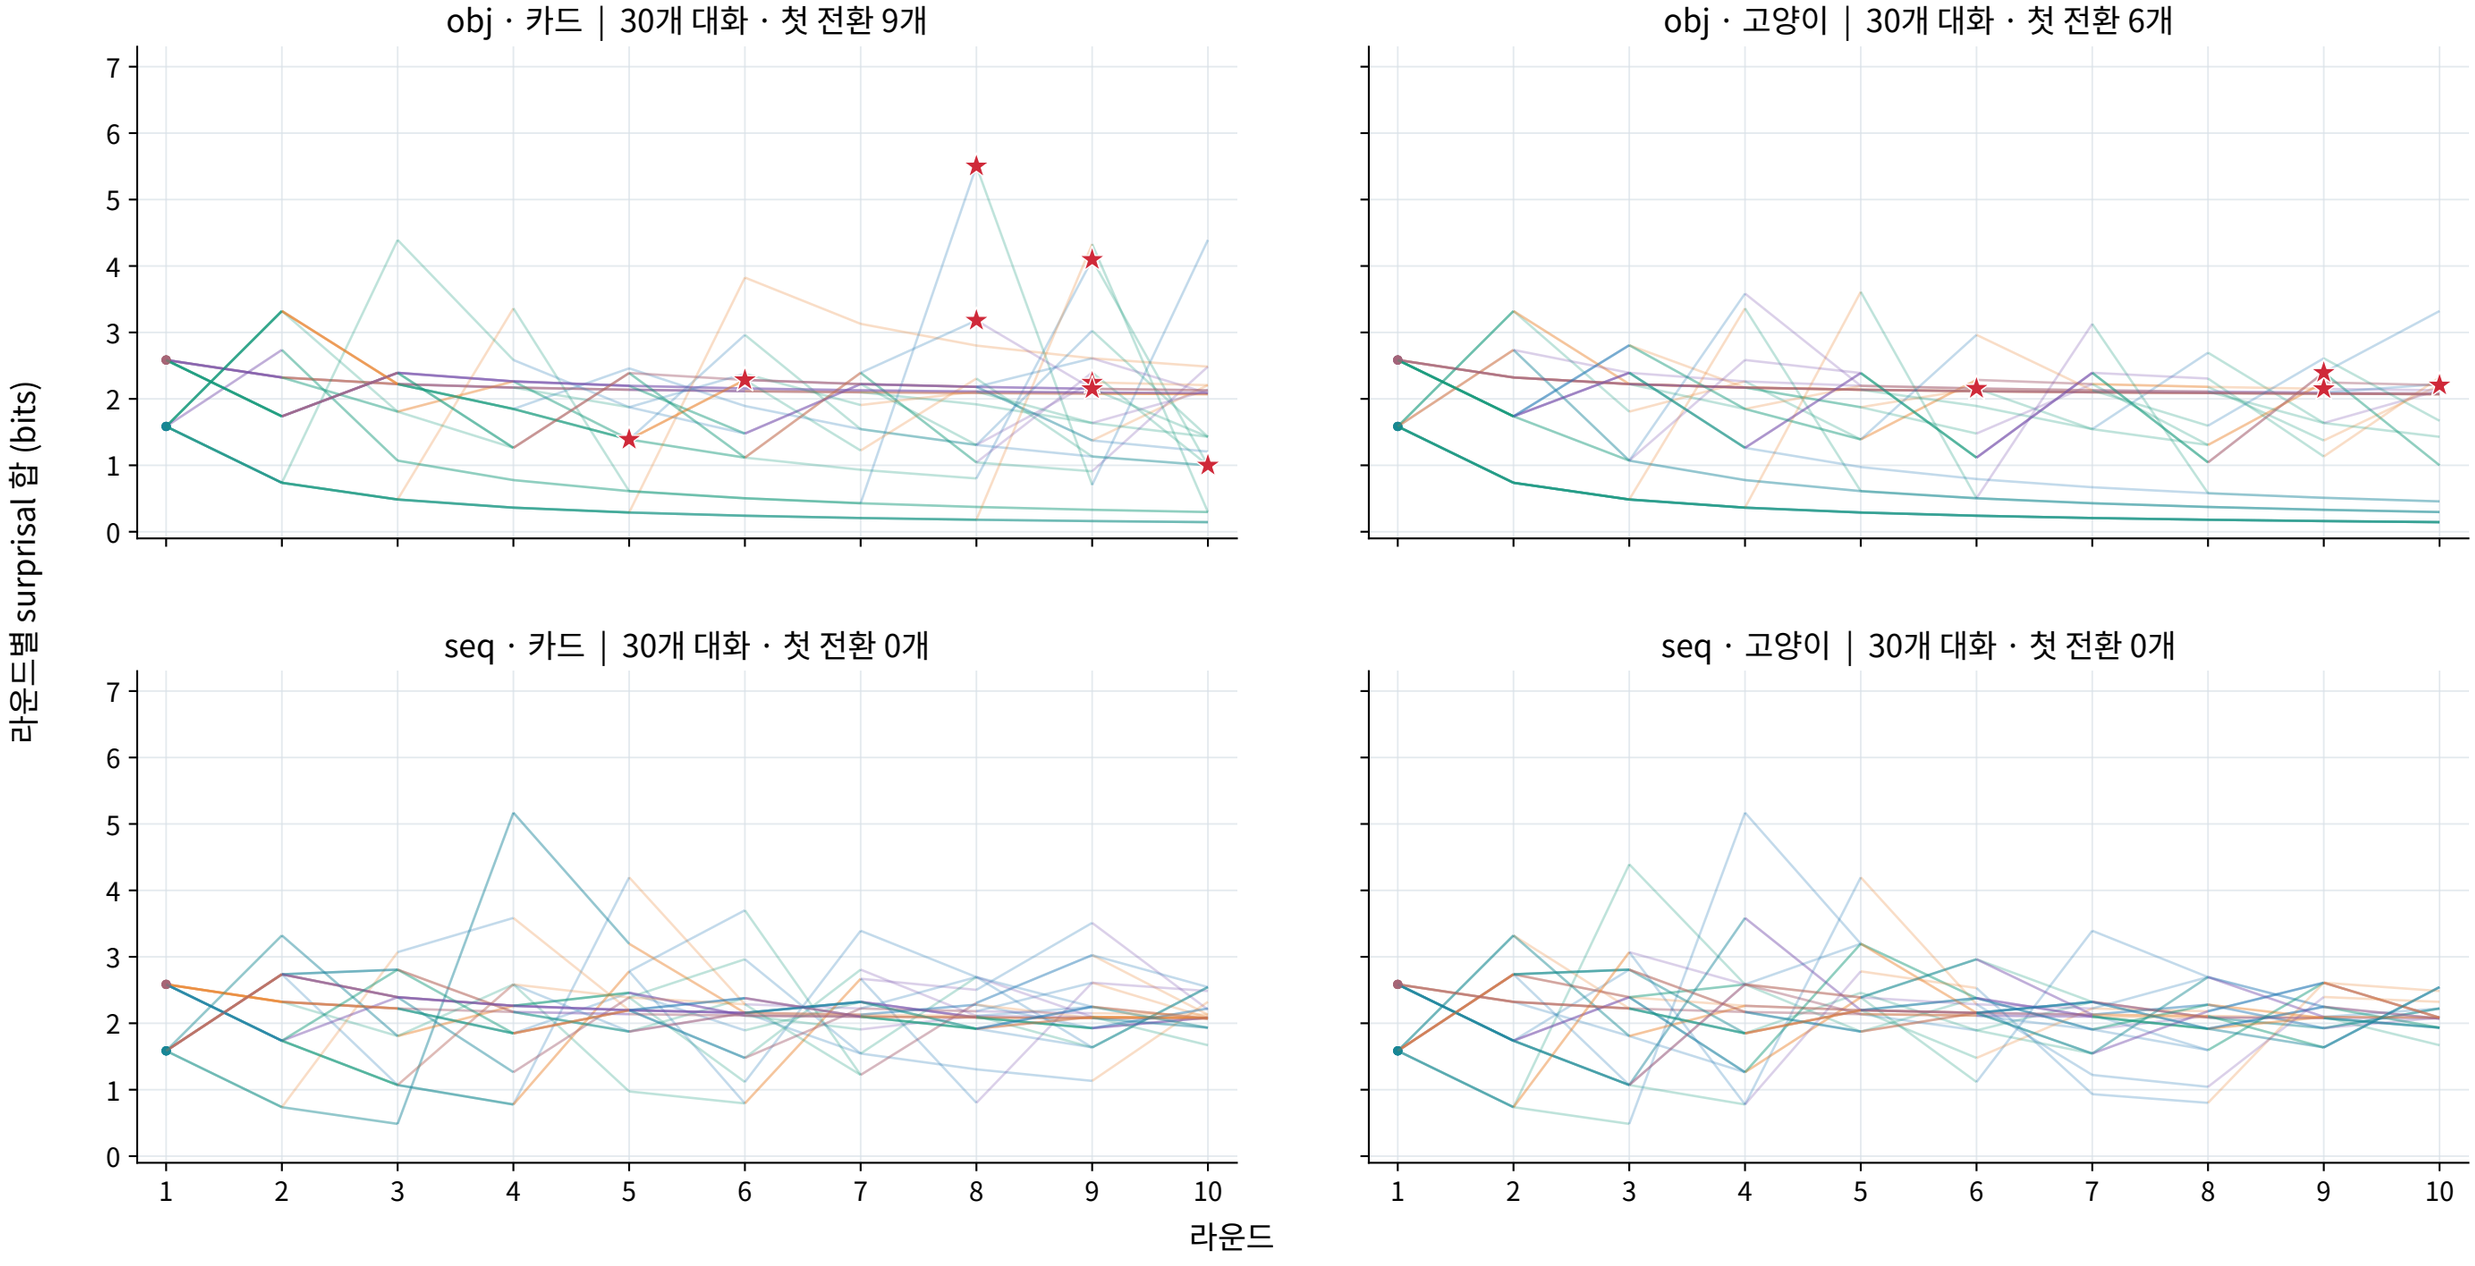


gpt-6-sol-medium | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.

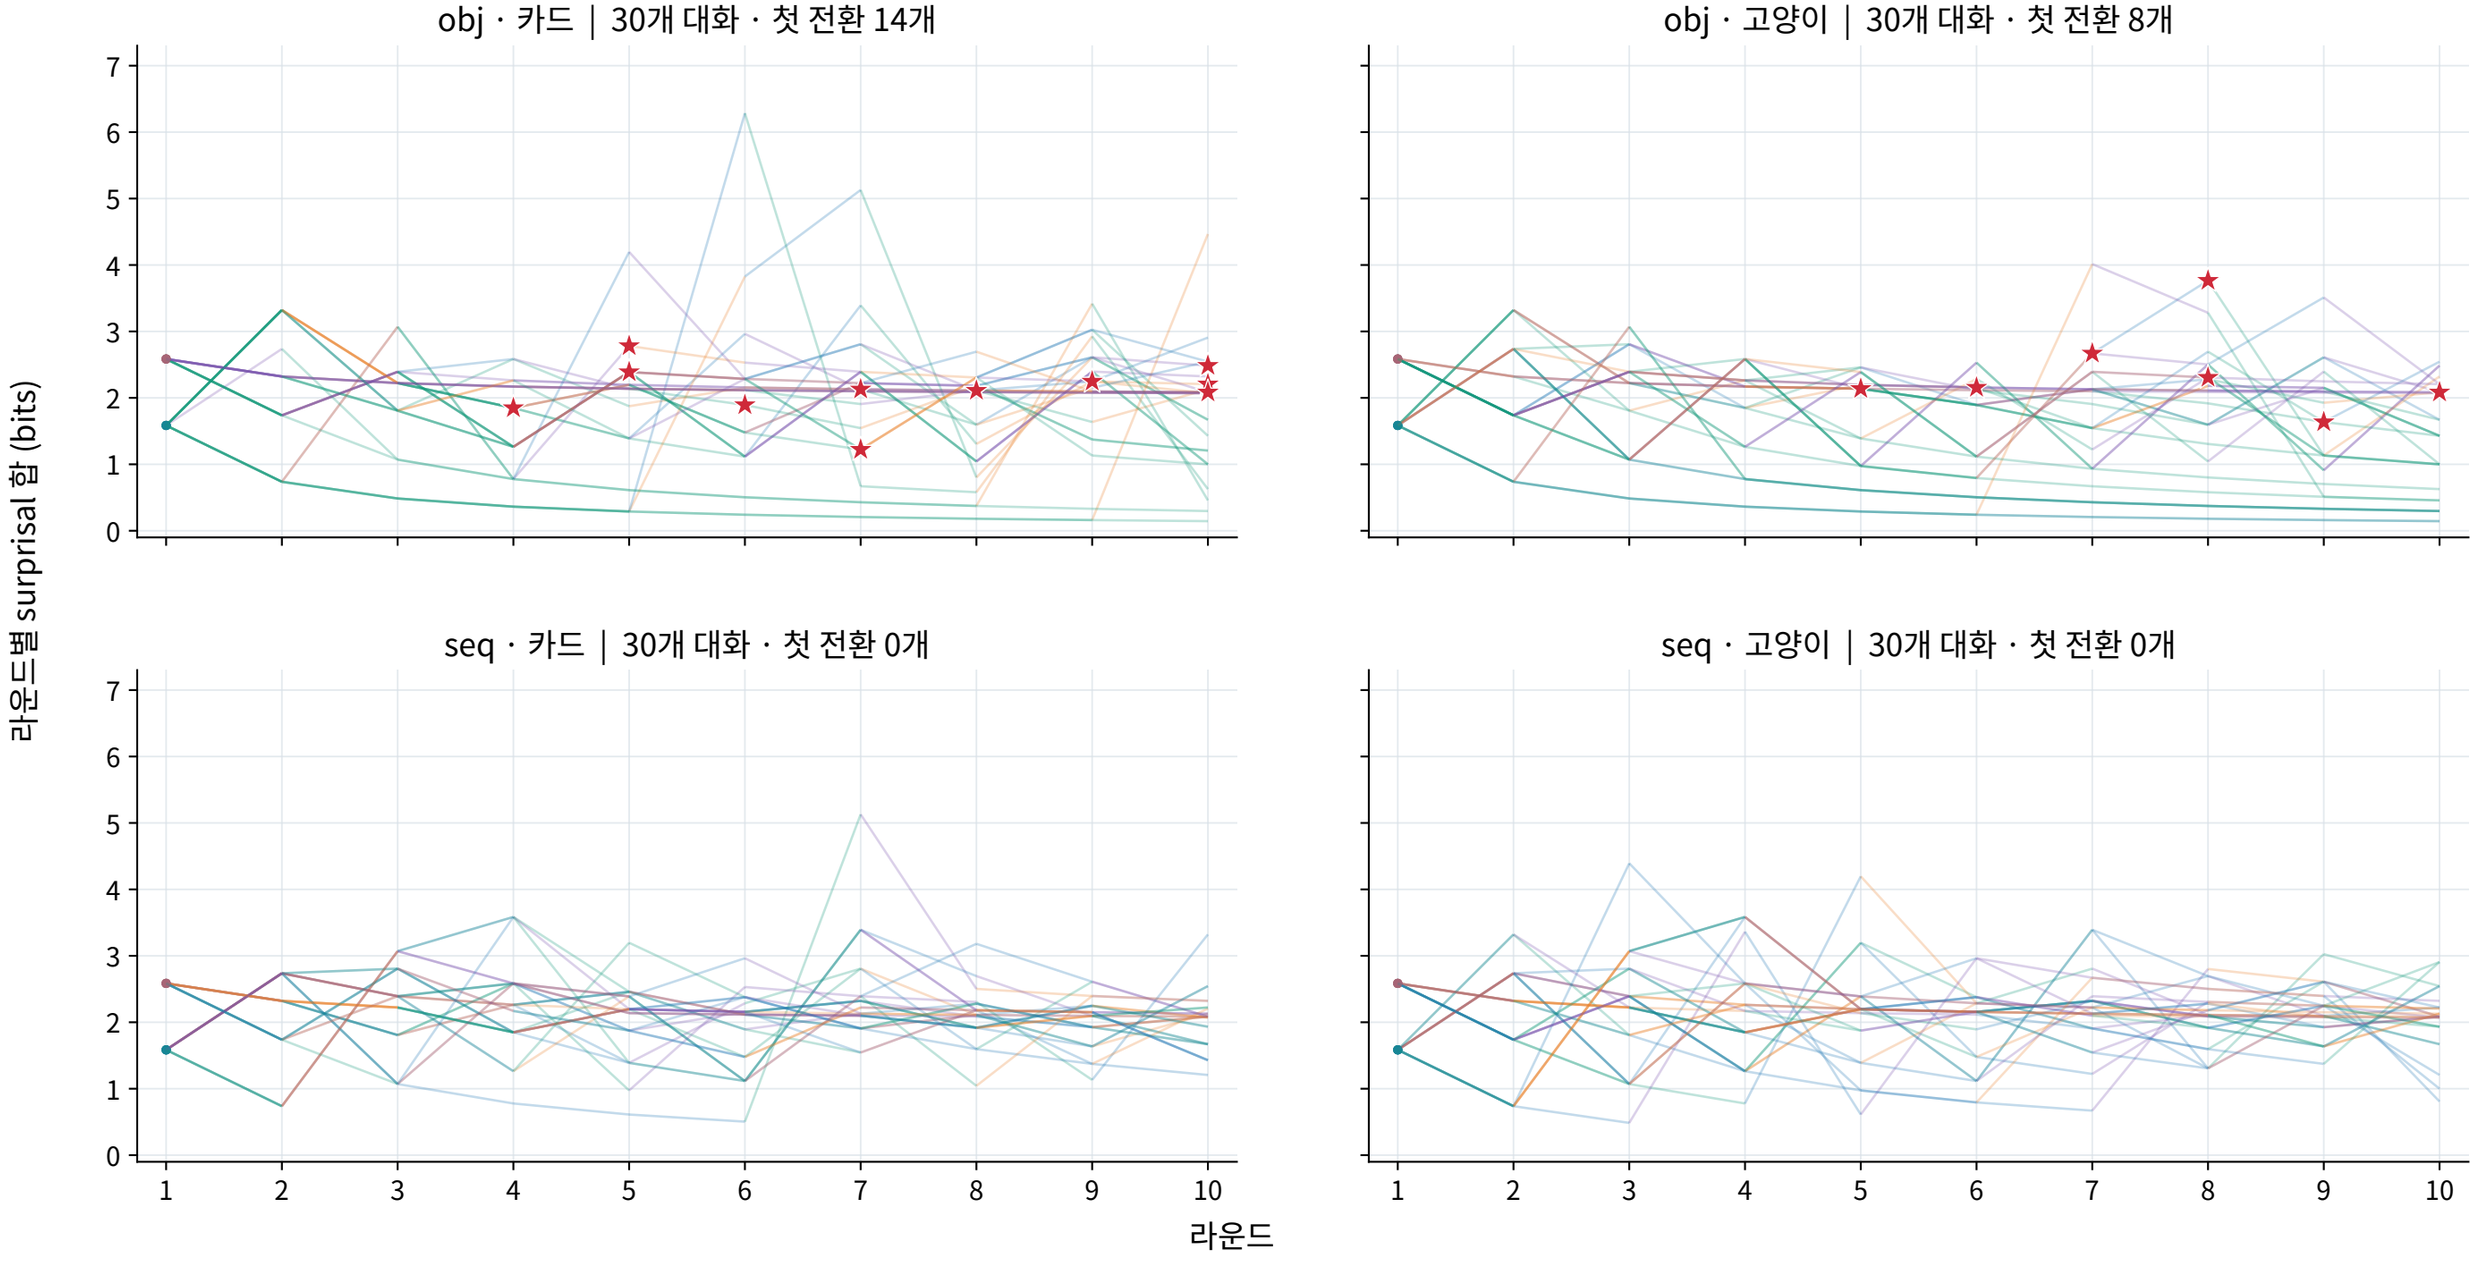


gpt-6-sol-high | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.

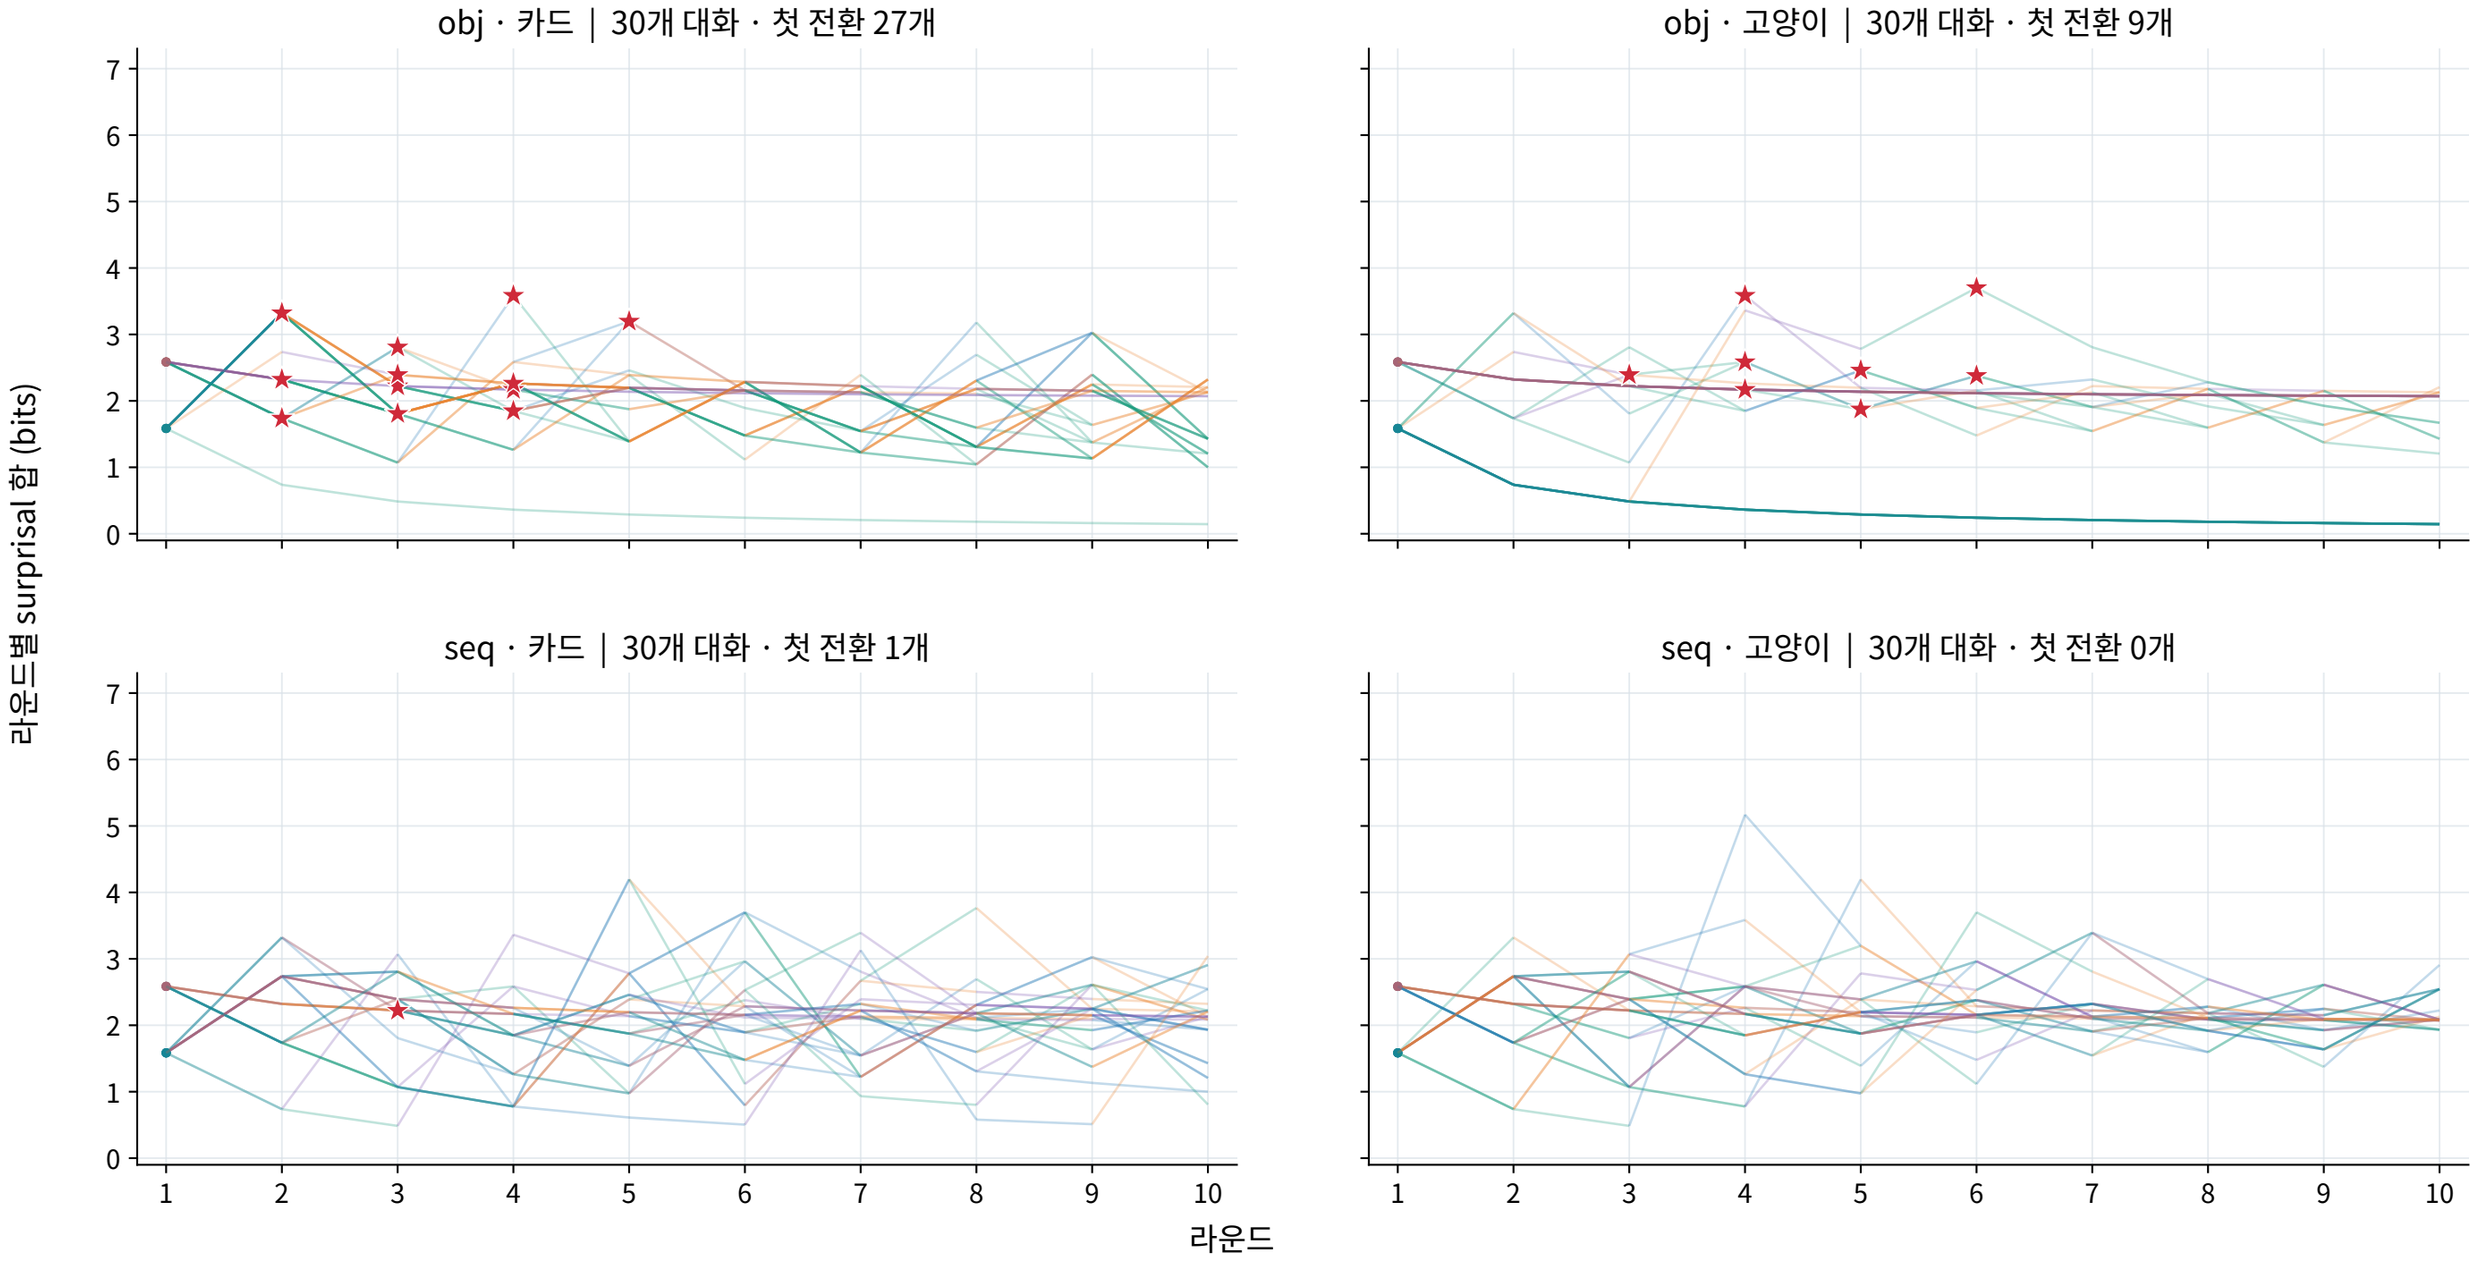


gpt-6-astra-low | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.

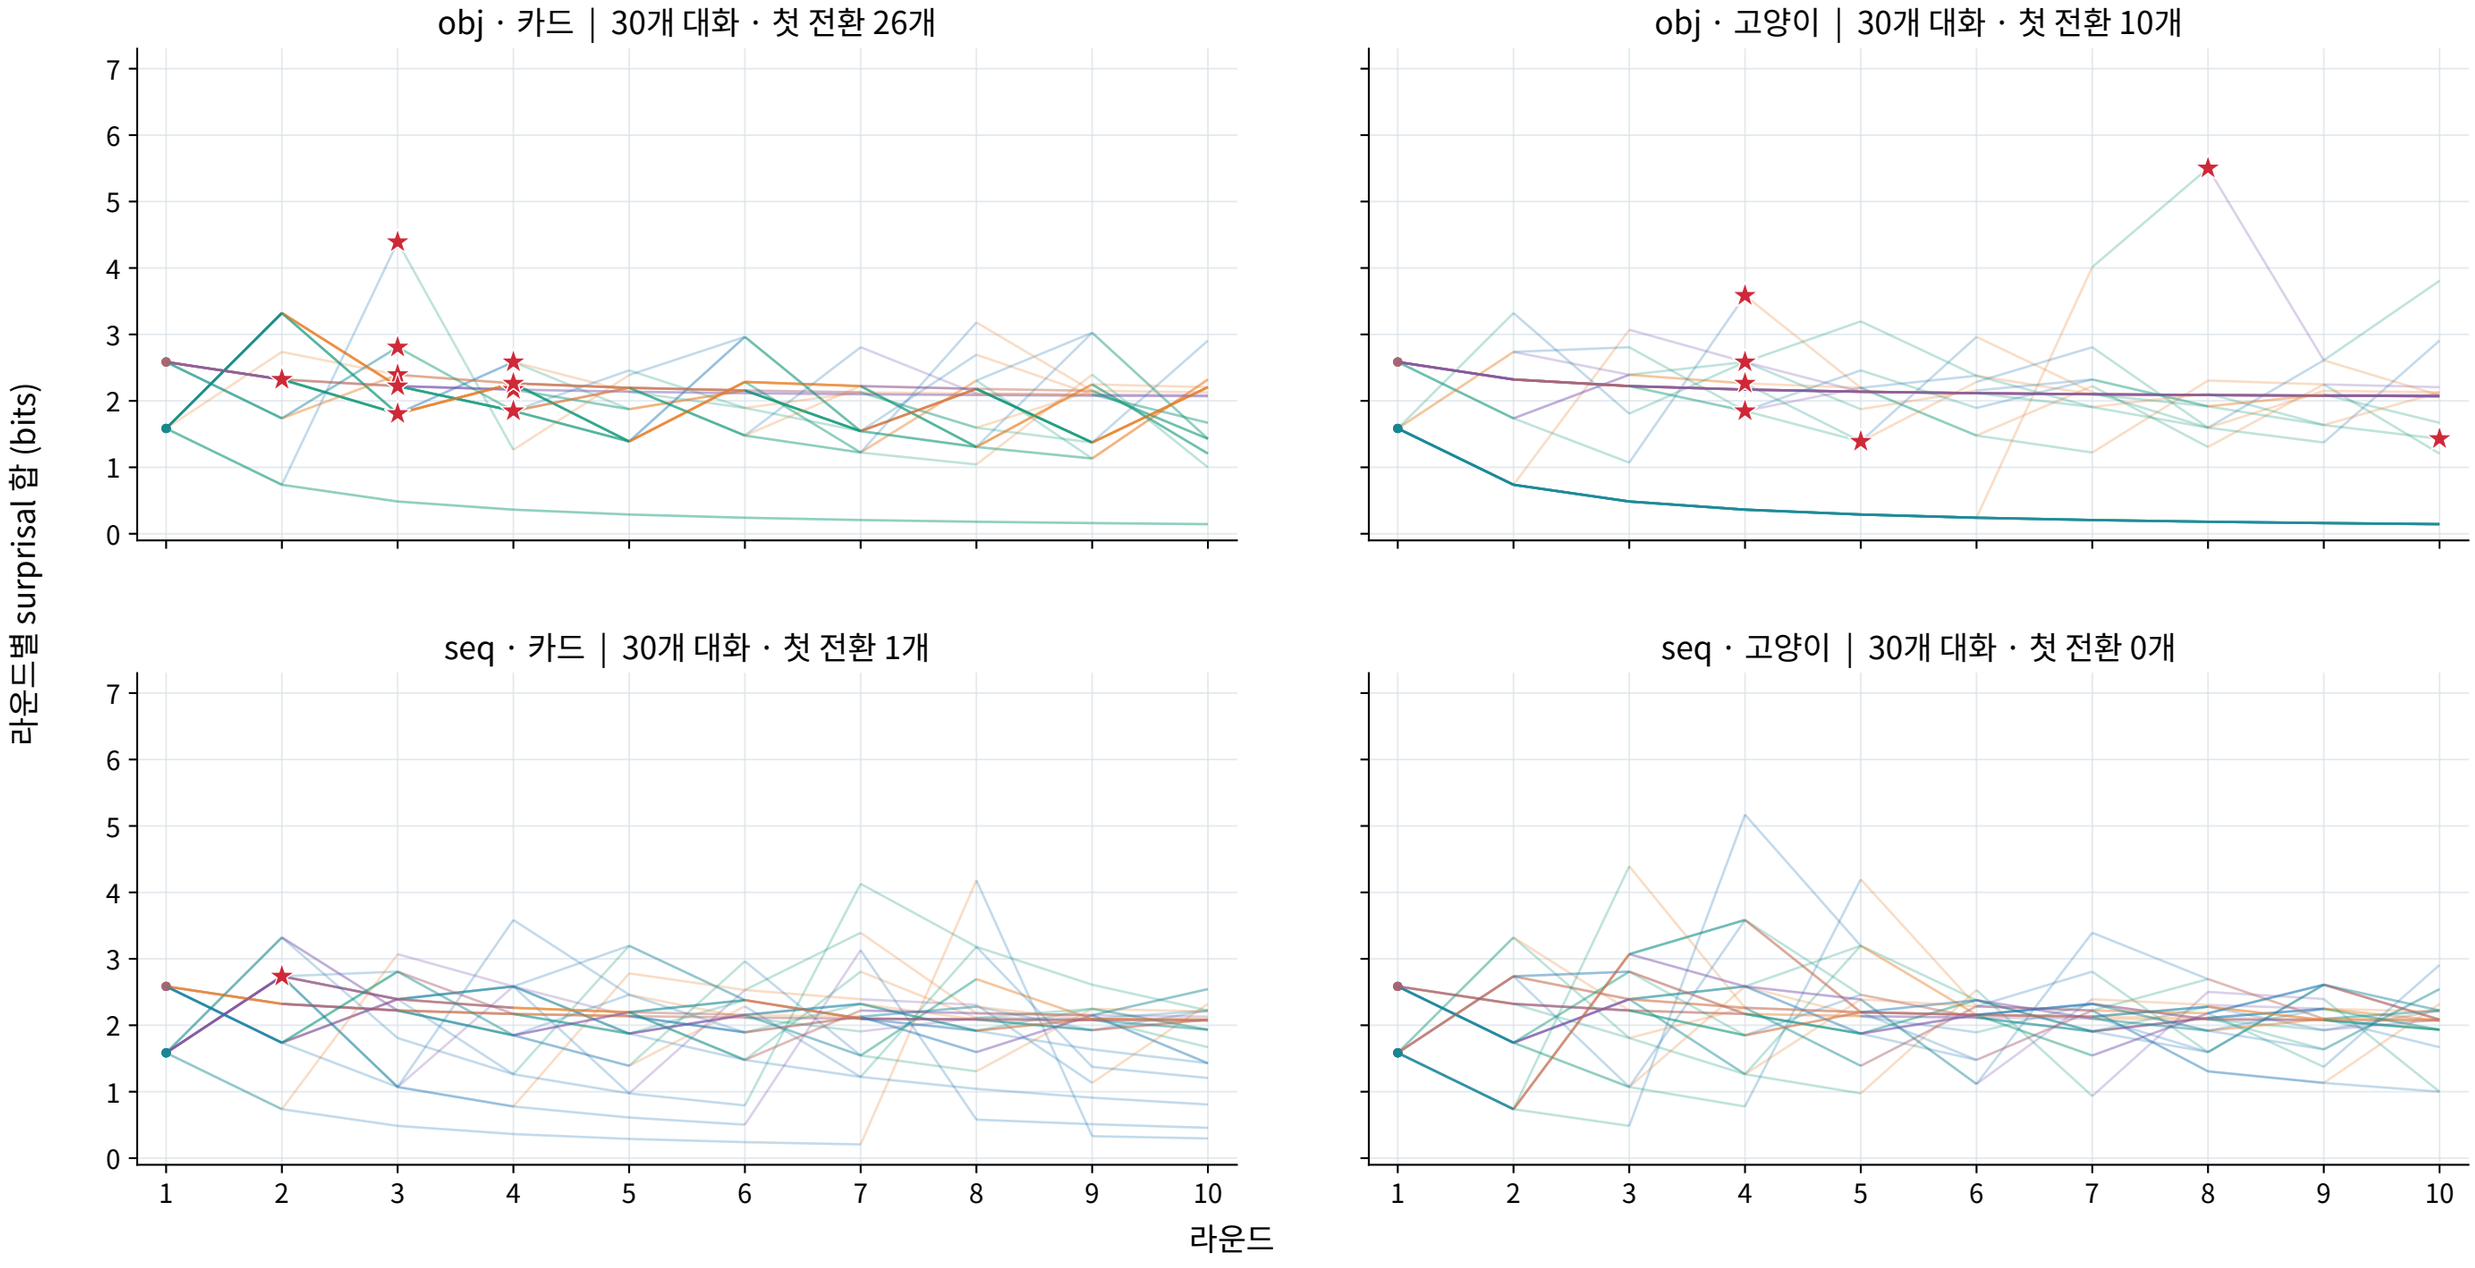


gpt-6-astra-medium | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.

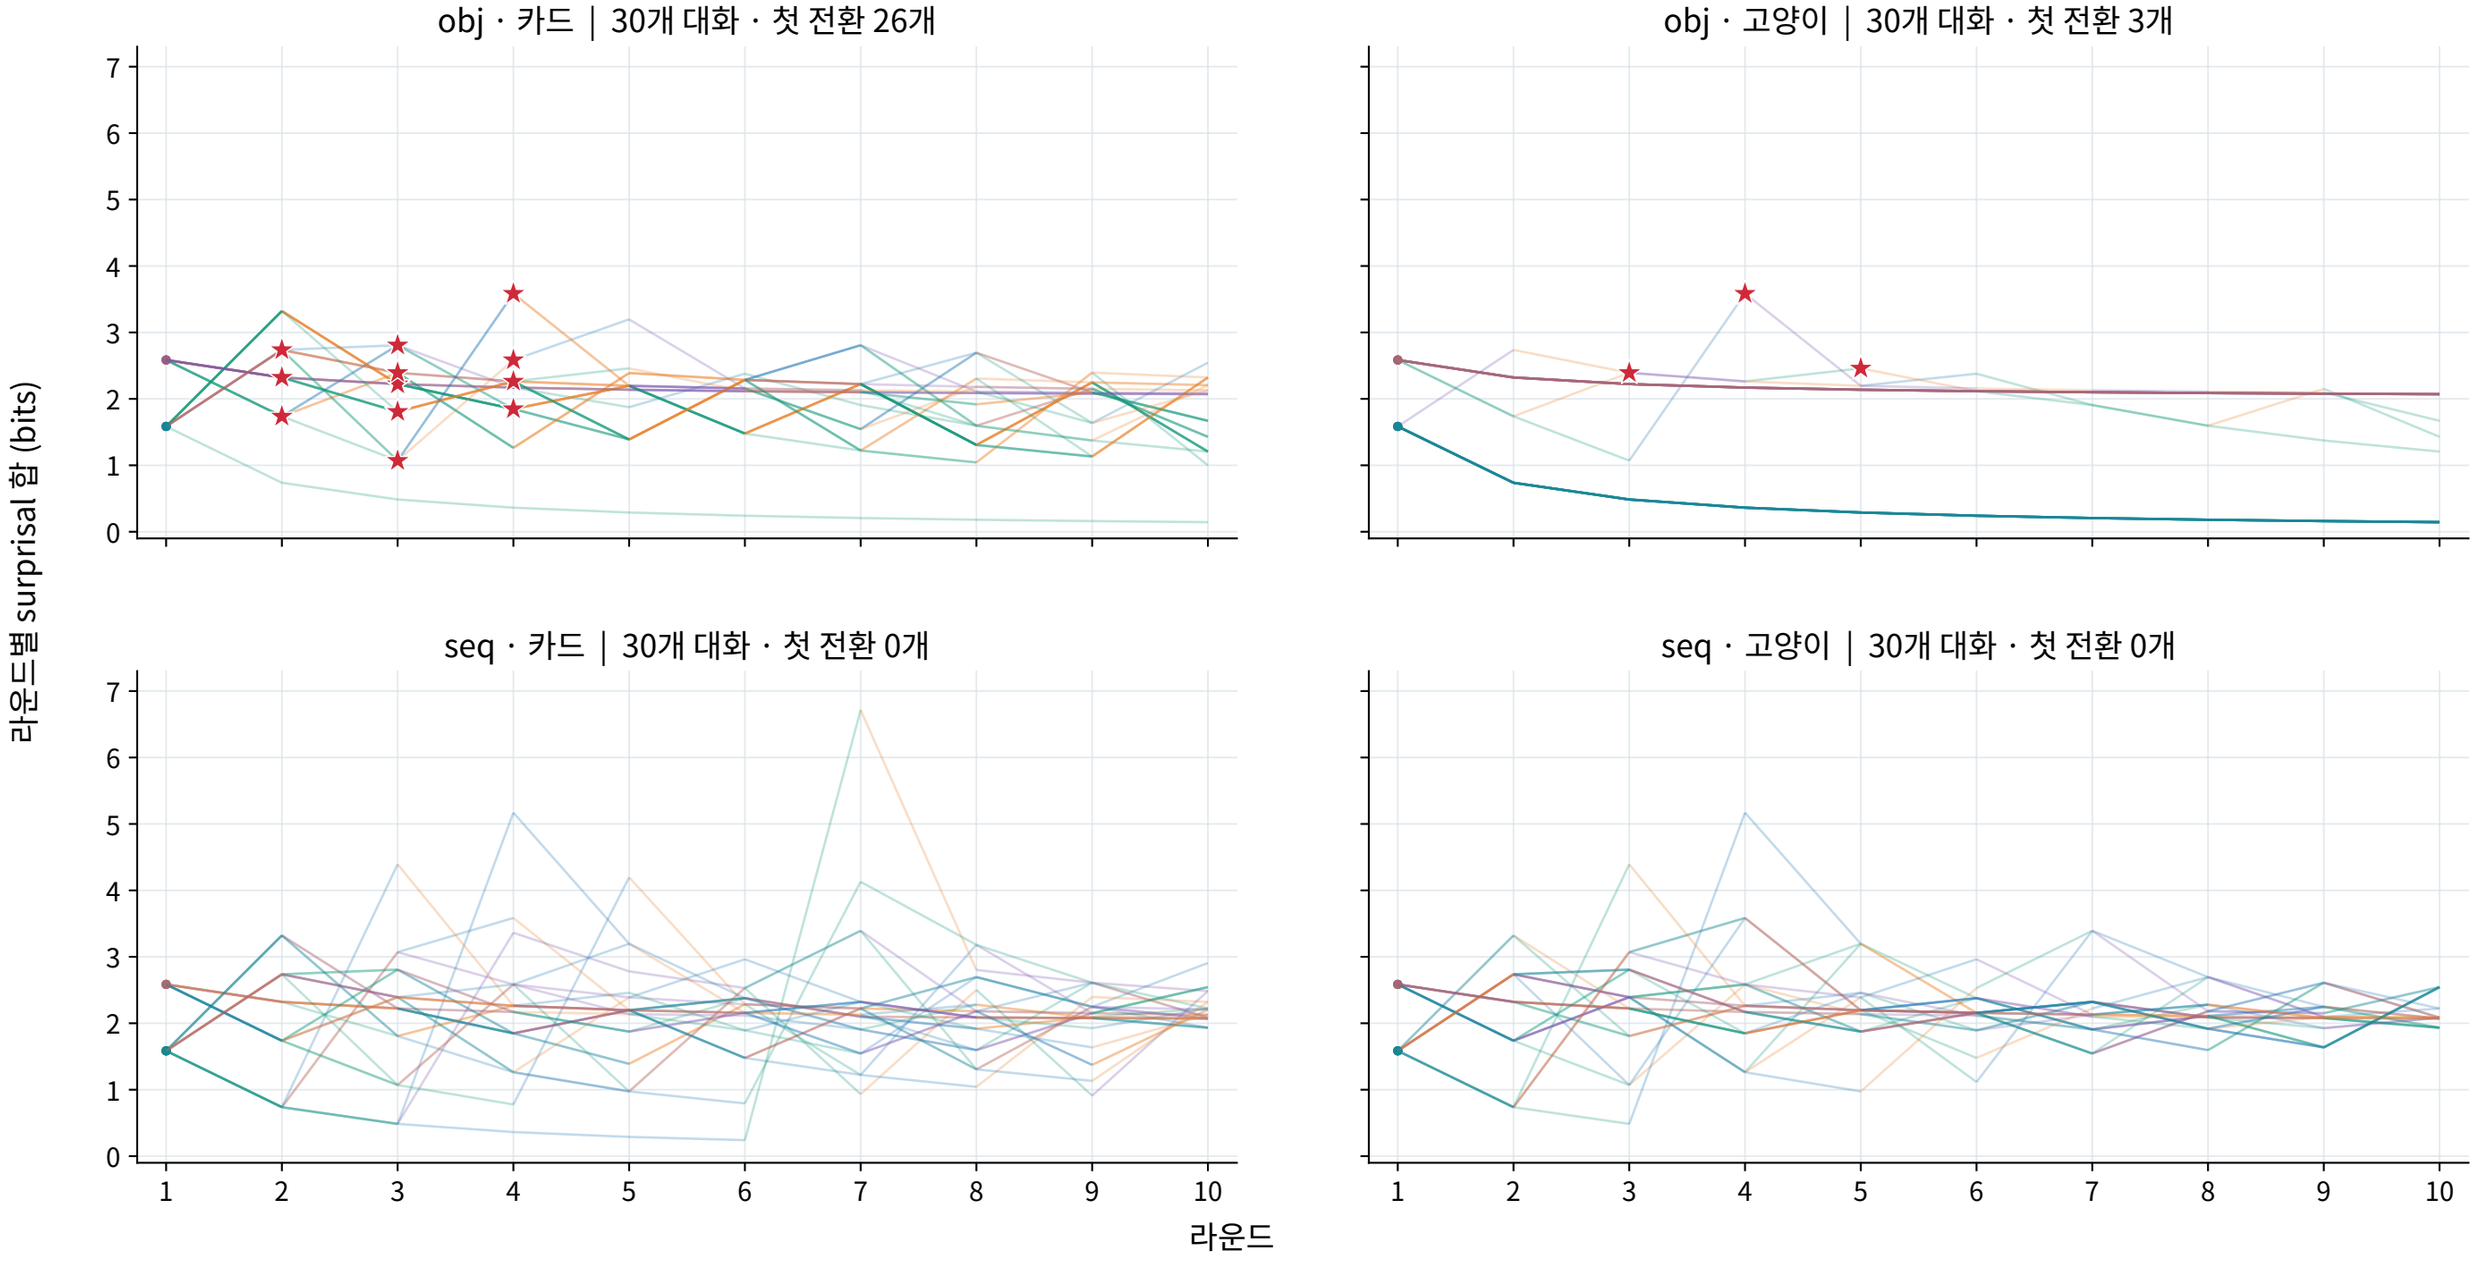


gpt-6-astra-high | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.

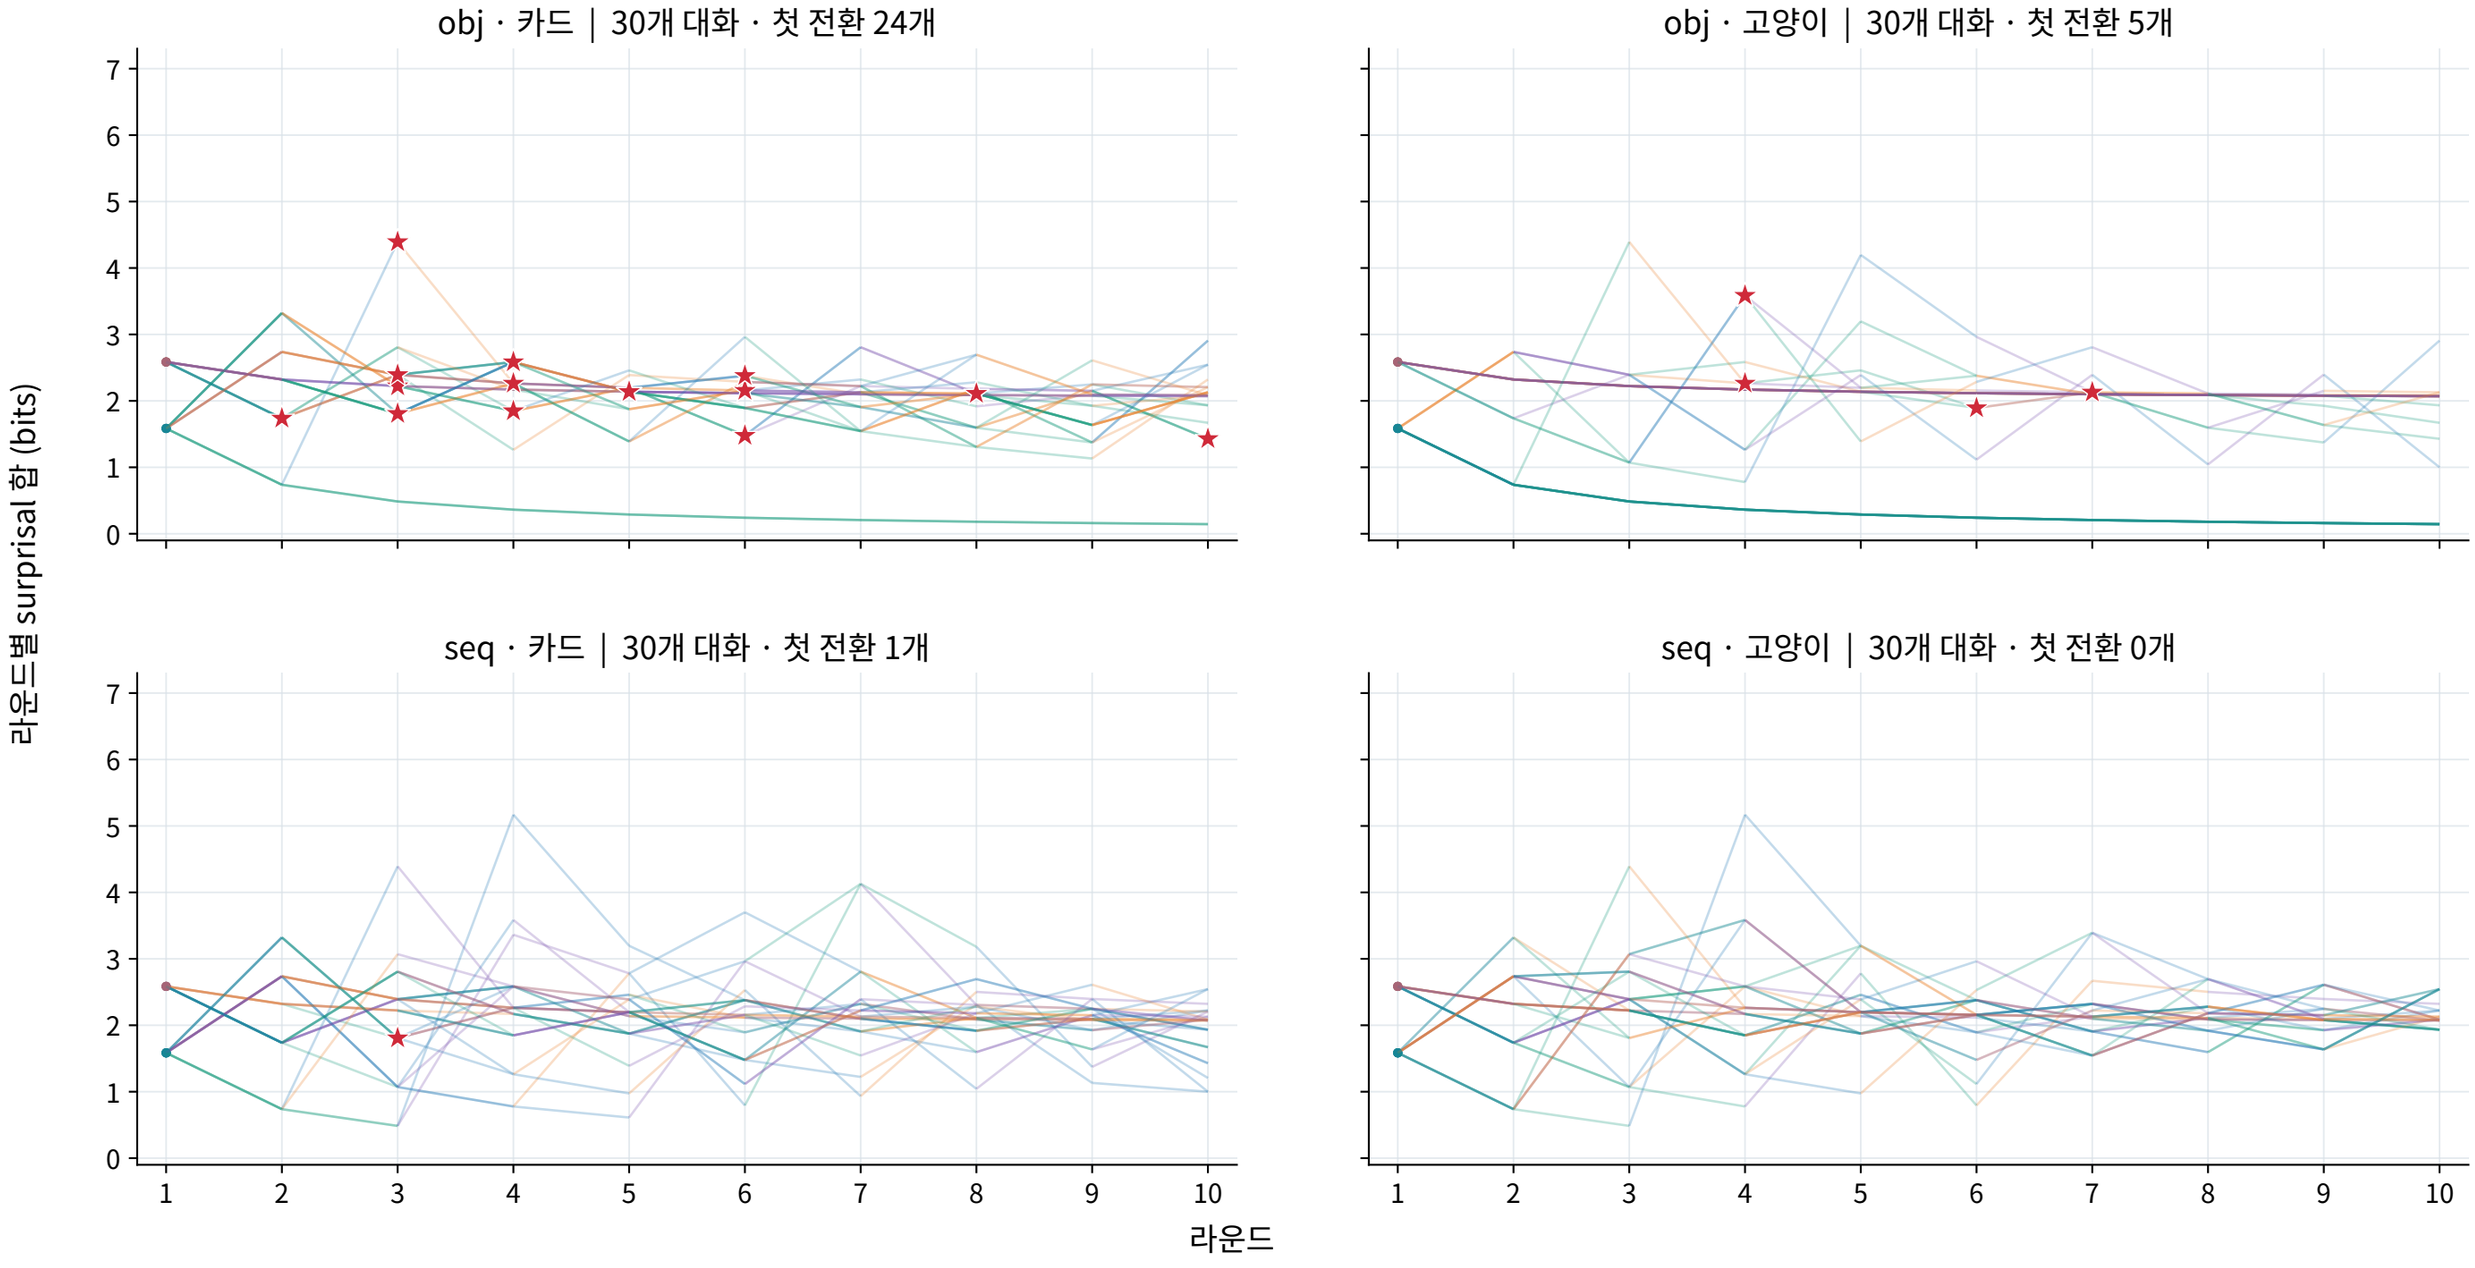


gpt-6.1-sol-low | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.

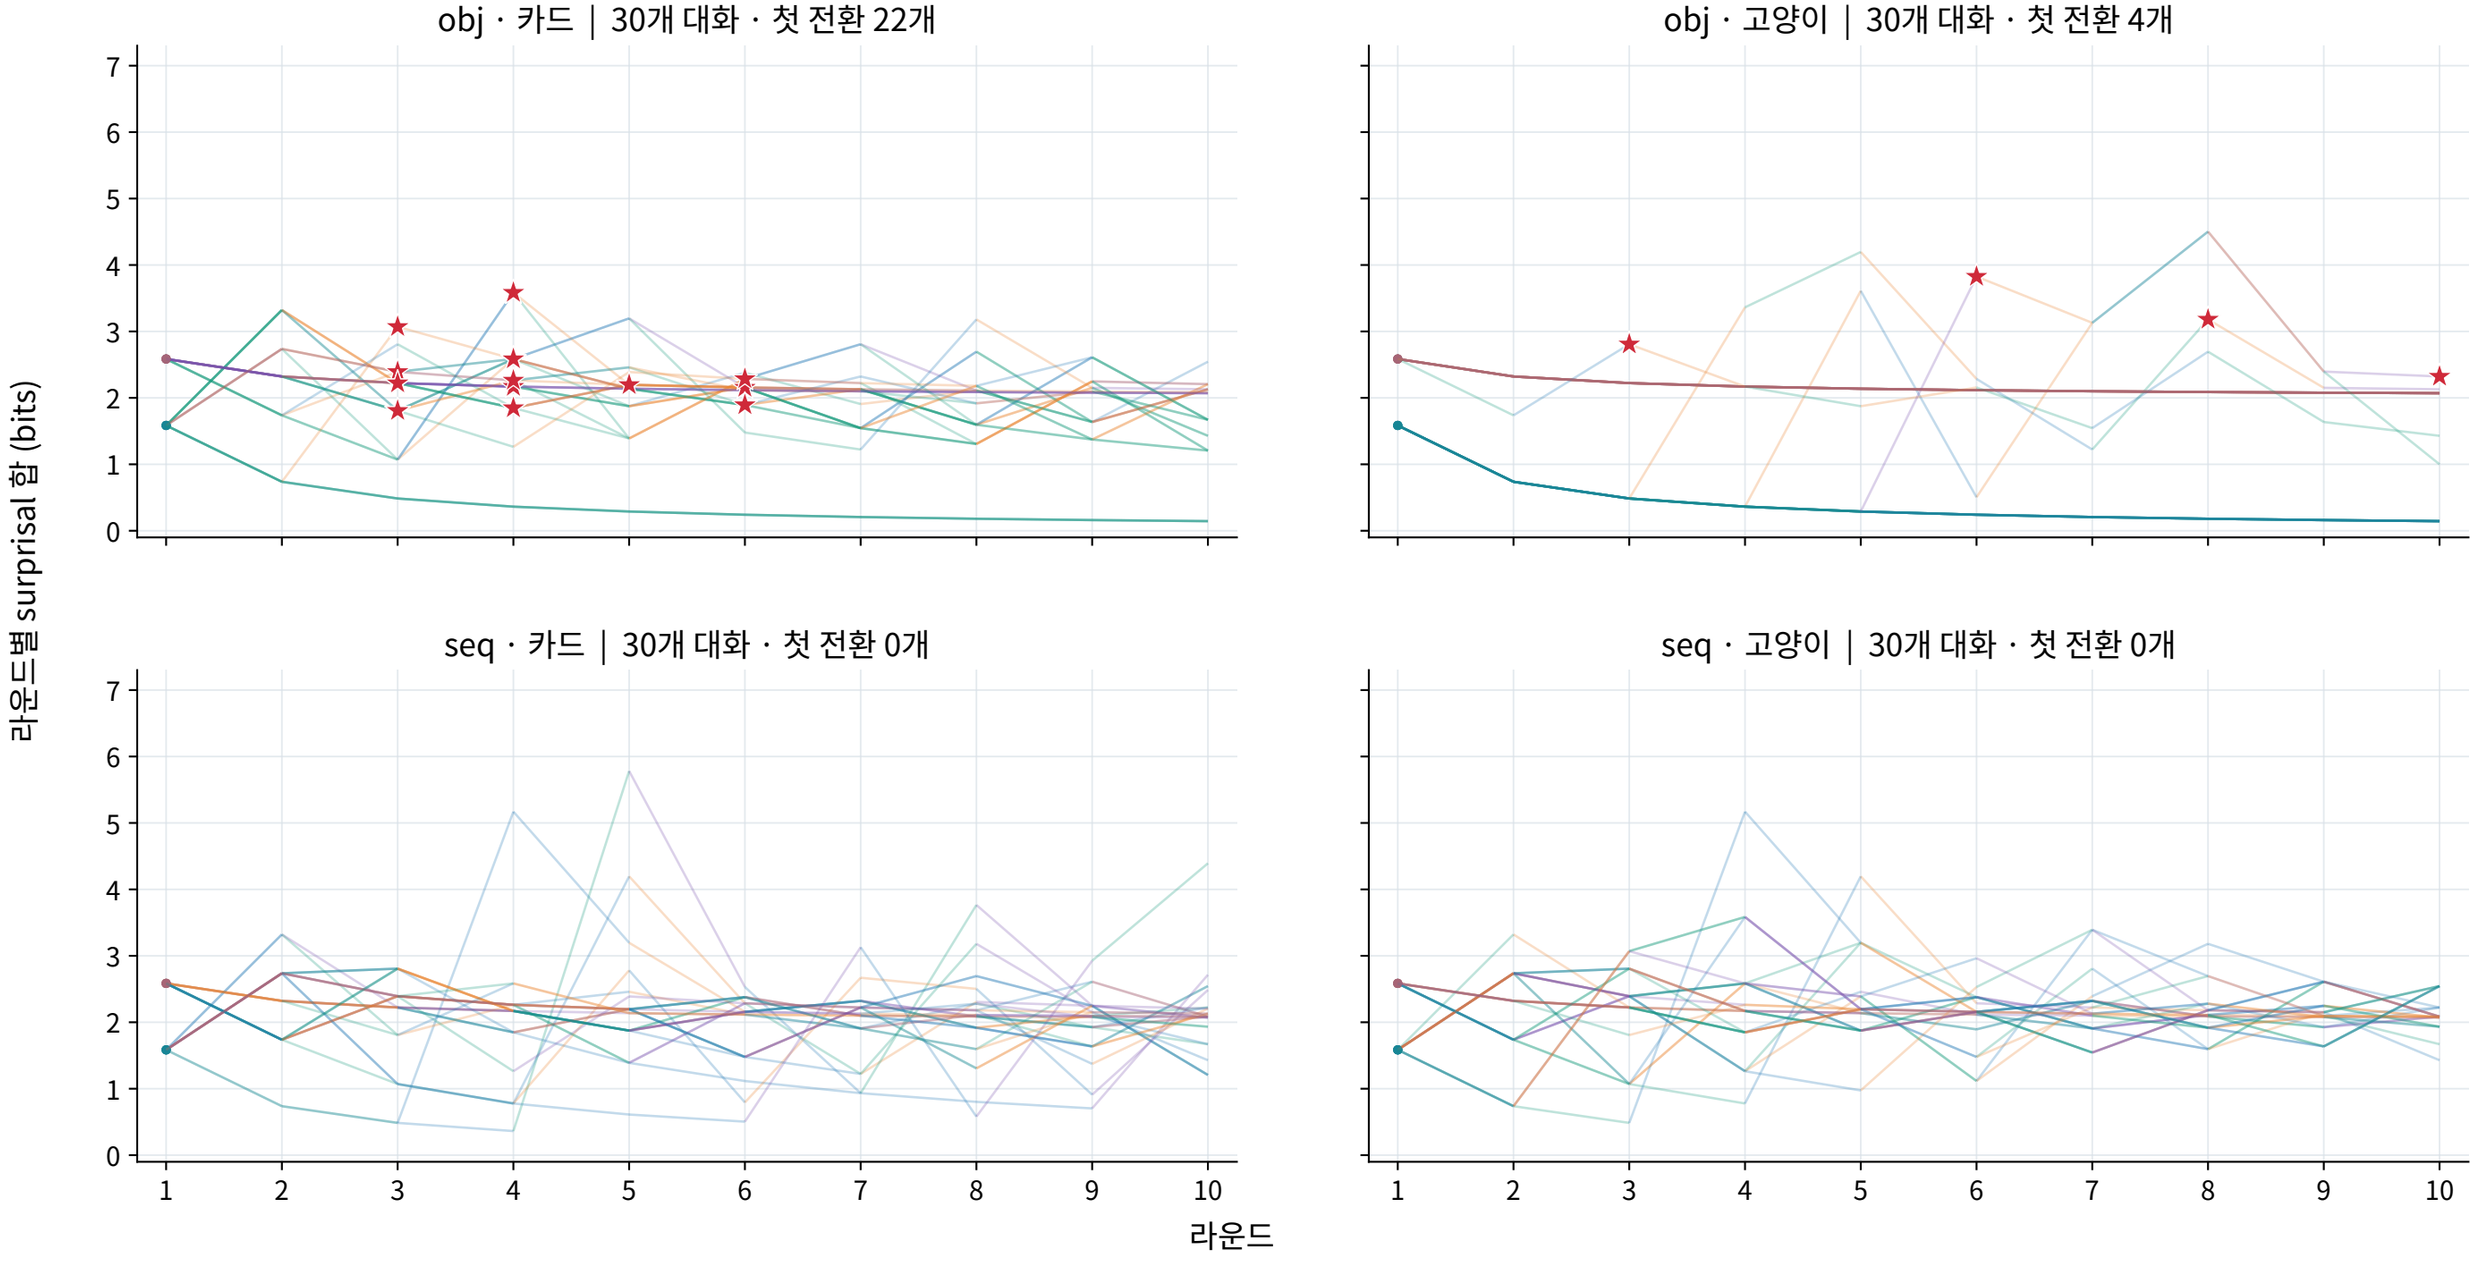


gpt-6.1-sol-medium | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.



gpt-6.1-sol-high | K/D 예측 위반과 통제 판단

선 하나 = 독립 대화 하나 · 선 색 = 해당 라운드의 K/D · ★ = 최초 통제 판단 전환

Y축은 그 라운드의 K/D 두 피드백에 대한 surprisal 합(bits). 높을수록 모델의 예상에서 벗어남.

대화마다 K/D를 50:50으로 시작해 발생 순서대로 갱신. 같은 궤적의 선과 별은 겹칠 수 있음.

